

# DCC008 - Cálculo Numérico

## Resolução de Sistemas de Equações Lineares

Bernardo Martins Rocha

Departamento de Ciência da Computação  
Universidade Federal de Juiz de Fora  
`bernardomartinsrocha@ice.ufjf.br`

# Conteúdo

- ▶ Introdução
- ▶ Conceitos fundamentais
- ▶ Métodos diretos
  - ▶ Sistemas triangulares
  - ▶ Eliminação de Gauss
  - ▶ Estratégias de Pivoteamento
  - ▶ Decomposição LU
  - ▶ Decomposição Cholesky e  $LDL^T$
  - ▶ Usos da decomposição
- ▶ Métodos iterativos
  - ▶ Introdução
  - ▶ Métodos Iterativos Estacionários
  - ▶ Método de Jacobi
  - ▶ Método de Gauss-Seidel
  - ▶ Análise de Convergência
  - ▶ Método SOR

# Introdução

Iremos estudar agora métodos computacionais para resolver um sistema de equações lineares da forma:

$$a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1$$

$$a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2$$

$$\vdots \qquad \qquad \qquad \vdots$$

$$a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m$$

onde

$$a_{ij} \in \mathbb{R}, \quad b_i \in \mathbb{R}, \quad x_j \in \mathbb{R}, \quad i = 1, \dots, m, \quad j = 1, \dots, n$$

Chamamos  $a_{ij}$  de coeficientes,  $b_i$  são constantes dadas e  $x_j$  são as variáveis ou incógnitas do problema.

# Introdução

## Exemplos de aplicações


Em uma vasta gama de problemas de ciências e engenharias a solução de um sistema de equações lineares é necessária. Podemos enumerar diversas áreas e problemas típicos, tais como:

- ▶ Solução de equações diferenciais
  - ▶ Solução de EDPs através do método dos elementos finitos, diferenças finitas ou volumes finitos.
  - ▶ Solução de EDOs
- ▶ Programação linear
- ▶ Análise de estruturas
- ▶ Sistemas de equações não-lineares
- ▶ Outros métodos numéricos
  - ▶ Interpolação, mínimos quadrados, etc.
- ▶ Circuitos elétricos

# Introdução

## Tensões em circuito elétrico

Calcular as tensões dos nós do circuito elétrico da figura abaixo:




Modelagem do problema:

- ▶ Lei de Kirchhoff: a soma das correntes que passam em cada nó do circuito é nula.
- ▶ Lei de Ohm: a corrente do nó  $j$  para o nó  $k$  é dada pela equação

$$I_{jk} = \frac{V_j - V_k}{R_{jk}}$$

# Introdução

## Tensões em circuito elétrico



Nó 1:  $I_{A1} + I_{21} + I_{31} + I_{41} = 0$

$$\frac{0-V_1}{1} + \frac{V_2-V_1}{1} + \frac{V_3-V_1}{2} + \frac{V_4-V_1}{2} = 0$$

$$-2V_1 + V_2 - V_1 + \frac{V_3}{2} - \frac{V_1}{2} + \frac{V_4}{2} - \frac{V_1}{2} = 0$$

$$-4V_1 + 2V_2 + V_3 - 2V_1 + 2V_4 = 0$$

$$-6V_1 + 2V_2 + V_3 + V_4 = 0$$

Nó 2:

$$3V_1 - 4V_2 + V_3 = 0$$

Nó 3:

$$3V_1 + 2V_2 - 13V_3 + 6V_4 = -254$$

Nó 4:

$$V_1 + 2V_3 - 3V_4 = 0$$

$$\begin{bmatrix} -6 & 2 & 1 & 1 \\ 3 & -4 & 1 & 0 \\ 3 & 2 & -13 & 6 \\ 1 & 0 & 2 & -3 \end{bmatrix} \begin{bmatrix} V_1 \\ V_2 \\ V_3 \\ V_4 \end{bmatrix}$$

# Introdução

## Tensões em circuito elétrico

$$\begin{bmatrix} -6 & 2 & 1 & 1 \\ 3 & -4 & 1 & 0 \\ 3 & 2 & -13 & 6 \\ 1 & 0 & 2 & -3 \end{bmatrix} \begin{bmatrix} V_1 \\ V_2 \\ V_3 \\ V_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ -254 \\ 0 \end{bmatrix}$$

Usando algum método que iremos estudar, encontramos a solução deste sistema


$$V^* = \begin{bmatrix} 25.7 \\ 31.75 \\ 49.6 \\ 41.6 \end{bmatrix}$$

ou seja  $V_1 = 25.7V$ ,  $V_2 = 31.75V$ ,  $V_3 = 49.6V$  e  $V_4 = 41.6V$ .

# Introdução

## Estruturas

Exemplo 1, Capítulo 3, Página, 105, Livro da Ruggiero.  
Determinar as forças que atuam nesta treliça.



Junção 2:

$$\sum F_x = -\alpha f_1 + f_4 + \alpha f_5 = 0$$

$$\sum F_y = -\alpha f_1 - f_3 - \alpha f_5 = 0$$

Procedendo de forma análoga para todas as junções obtém-se um sistema linear de 17 equações e 17 variáveis ( $f_1, \dots, f_{17}$ ).



# Conceitos fundamentais

Antes de estudar os métodos para solução deste tipo de problema, vamos rever alguns conceitos fundamentais de Álgebra Linear necessários para o desenvolvimento e análise dos métodos.

## Matrizes

Uma matriz é um conjunto de elementos (números reais ou complexos) dispostos de forma retangular. O tamanho ou dimensão é definido pelo seu número de linhas e colunas. Uma matriz com  $m$  linhas e  $n$  colunas é dita ser  $m \times n$  ( $m$  por  $n$ ) e se  $m = n$ , então dizemos que a matriz é quadrada.

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$$

Um elemento  $a_{ij}$  da matriz é referenciado por 2 índices: o primeiro indica a linha e o segundo a coluna.

# Conceitos fundamentais

## Matrizes especiais

- ▶ Matriz coluna e matriz linha

Matriz coluna:  $n \times 1$

Matriz linha:  $1 \times n$

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \end{bmatrix}$$

$$\begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{n1} \end{bmatrix}$$

- ▶ Matriz nula:

$$a_{ij} = 0, \quad \forall i, j$$

- ▶ Matriz diagonal:

$$d_{ij} = 0, \quad \forall i \neq j$$

- ▶ Matriz identidade:

$$e_{ij} = 1, \quad \forall i = j$$

$$e_{ij} = 0, \quad \forall i \neq j$$

# Conceitos fundamentais

## Matrizes especiais

- ▶ Matriz triangular inferior: acima da diagonal principal é nula

$$b_{ij} = 0, \quad \forall i < j, \quad \text{Exemplo: } \mathbf{B} = \begin{bmatrix} b_{11} & 0 & 0 \\ b_{21} & b_{22} & 0 \\ b_{31} & b_{32} & b_{33} \end{bmatrix}$$

- ▶ Matriz triangular superior: abaixo da diagonal principal é nula

$$c_{ij} = 0, \quad \forall i > j, \quad \text{Exemplo: } \mathbf{C} = \begin{bmatrix} c_{11} & c_{12} & c_{13} \\ 0 & c_{22} & c_{23} \\ 0 & 0 & c_{33} \end{bmatrix}$$

- ▶ Matriz simétrica:

$$m_{ij} = m_{ji}, \quad \forall i, j$$

# Conceitos fundamentais

## Operações matriciais

### Transposição

A transposta de uma matriz  $\mathbf{A}$ , denotada por  $\mathbf{A}^T$ , é uma matriz obtida trocando-se as suas linhas pelas colunas.

Exemplo:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix}, \quad \mathbf{A}^T = \begin{bmatrix} 1 & 5 & 7 & 10 \\ 2 & 5 & 8 & 11 \\ 3 & 6 & 9 & 12 \end{bmatrix}$$

### Adição e Subtração

Sejam  $\mathbf{A}$  e  $\mathbf{B}$  matrizes  $m \times n$ . Então a matriz  $\mathbf{C}$  é  $m \times n$  e seus elementos são dados por

$$c_{ij} = a_{ij} + b_{ij}, \quad \forall i, j$$

# Conceitos fundamentais

## Operações matriciais

### Multiplicação por escalar

Seja  $\mathbf{A}$  uma matriz  $m \times n$  e seja  $k \in \mathbb{R}$  um escalar qualquer. Então  $\mathbf{B} = k\mathbf{A}$  é tal que

$$b_{ij} = k a_{ij}, \quad \forall i, j$$

### Multiplicação matriz-vetor

Seja  $\mathbf{A}$  uma matriz  $m \times n$  e  $\mathbf{x}$  um vetor  $n \times 1$ , então a multiplicação de  $\mathbf{A}$  por  $\mathbf{x}$  é

$$\mathbf{v} = \mathbf{Ax} \quad \Rightarrow \quad v_i = \sum_{j=1}^n a_{ij} x_j, \quad i = 1, 2, \dots, m$$

### Exemplo

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 5 \\ 11 \\ 17 \end{bmatrix}$$

# Conceitos fundamentais

## Operações matriciais

### Multiplicação matriz-matriz

Seja **A** uma matriz  $m \times p$  e **B** uma matriz  $p \times n$ . O resultado da multiplicação **AB** é uma matriz **C** de tamanho  $m \times n$ .

$$c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}, \quad i = 1, \dots, m, \quad j = 1, \dots, n$$

Exemplo:

$$\mathbf{A} = \begin{bmatrix} 3 & 1 & 0 \\ -1 & 6 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} -3 & 2 \\ 4 & 9 \\ 8 & -1 \end{bmatrix}$$

$$\mathbf{C} = \mathbf{AB} = \begin{bmatrix} -5 & 15 \\ 59 & 48 \end{bmatrix}$$

# Conceitos fundamentais

## Operações matriciais

### Produto Interno e Produto Externo

O produto interno ou escalar entre dois vetores  $\mathbf{x}$  e  $\mathbf{y}$ , ambos de tamanho  $n$  resulta em um valor escalar  $k$  dado por

$$k = \mathbf{x}^T \mathbf{y} = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = \sum_{i=1}^n x_i y_i$$

O produto externo entre  $\mathbf{x}(m \times 1)$  e  $\mathbf{y}(n \times 1)$  resulta em uma matriz  $\mathbf{M}$  de tamanho  $m \times n$  dada por

$$m_{ij} = x_i y_j, \quad i = 1, \dots, m, \quad j = 1, \dots, n$$

Exemplo:

$$\mathbf{x} = \begin{bmatrix} 5 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ 3 \\ 4 \end{bmatrix}, \quad \mathbf{x}^T \mathbf{y} = 10, \quad \mathbf{x} \mathbf{y}^T = \mathbf{M} = \begin{bmatrix} 5 & 15 & 20 \\ -1 & -3 & -4 \\ 2 & 6 & 8 \end{bmatrix}$$

# Conceitos fundamentais

## Operações matriciais

### Determinante

Seja  $\mathbf{A}$  uma matriz quadrada de ordem  $n$ . Então  $\mathbf{A}$  possui um número associado chamado de determinante, o qual pode ser calculado pela seguinte fórmula:

$$\det(\mathbf{A}) = a_{11}\det(\mathbf{M}_{11}) - a_{12}\det(\mathbf{M}_{12}) + \dots + (-1)^{n+1}a_{1n}\det(\mathbf{M}_{1n})$$

onde  $\mathbf{M}_{ij}$  é a matriz resultante da remoção da linha  $i$  e da coluna  $j$  da matriz  $\mathbf{A}$ . Em particular

$$\mathbf{A} = [a_{11}] \Rightarrow \det(\mathbf{A}) = a_{11}, \quad \mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \Rightarrow \det(\mathbf{A}) = a_{11}a_{22} - a_{12}a_{21}$$

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

$$\begin{aligned} \det(\mathbf{A}) &= a_{11}(a_{22}a_{33} - a_{32}a_{23}) \\ &\quad - a_{12}(a_{21}a_{33} - a_{31}a_{23}) \\ &\quad + a_{13}(a_{21}a_{32} - a_{31}a_{22}) \end{aligned}$$



# Conceitos fundamentais

## Operações matriciais

### Definição (Matriz singular)

*Uma matriz com  $\det(\mathbf{A}) = 0$  é dita **singular**. Por outro lado quando  $\det(\mathbf{A}) \neq 0$  dizemos que a matriz é **não-singular**.*

### Definição (Vetores Linearmente Independentes)

*Um conjunto de vetores  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  é dito ser linearmente independente (LI) se*

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \dots + c_k\mathbf{x}_k = \mathbf{0}$$

*somente se  $c_1 = c_2 = \dots = c_k = 0$ . Caso contrário, isto é, quando  $c_1, c_2, \dots, c_k$  não são todos nulos, dizemos que o conjunto de vetores é linearmente dependente (LD).*

# Conceitos fundamentais

## Operações matriciais

### Definição (Posto)

*O posto (ou rank) de uma matriz  $\mathbf{A}$  de tamanho  $m \times n$  é definido como o número máximo de vetores linhas (ou de vetores colunas) linearmente independentes de  $\mathbf{A}$ . Escrevemos  $\text{posto}(\mathbf{A}) = r$  e temos que  $r \leq \min(m, n)$ .*

### Definição (Inversa)

*A inversa de uma matriz  $\mathbf{A}$  quadrada  $n \times n$  é representada por  $\mathbf{A}^{-1}$  e definida de tal forma que*

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$$

*onde  $\mathbf{I}$  é a matriz identidade de ordem  $n$ .*

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix}, \quad \mathbf{A}^{-1} = \begin{bmatrix} \frac{3}{2} & -\frac{1}{2} \\ -2 & 1 \end{bmatrix}$$

# Sistemas Lineares

Um sistema de equações lineares consiste em um conjunto de  $m$  equações polinomiais com  $n$  variáveis  $x_i$  de grau um, isto é

$$a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1$$

$$a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2$$

$$\vdots$$
$$\vdots$$

$$a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m$$

o qual pode ser escrito da seguinte forma matricial  $\mathbf{Ax} = \mathbf{b}$  onde

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

onde  $\mathbf{A}$  é a matriz dos coeficientes,  $\mathbf{b}$  é o vetor dos termos independentes e  $\mathbf{x}$  é o vetor solução procurado.

# Classificação de Sistemas

## Número de Soluções

Vamos considerar apenas sistemas cujas matrizes dos coeficientes são quadradas, isto é, onde  $\mathbf{A} \in \mathbb{R}^{n \times n}$ .

Iremos tratar do caso onde  $\mathbf{A}$  não é uma matriz quadrada e  $m > n$  mais adiante, quando estudarmos mínimos quadrados.

Para o sistema  $\mathbf{Ax} = \mathbf{b}$ , temos as seguintes possibilidades quanto ao número de soluções:

- (a) uma única solução
- (b) infinitas soluções
- (c) sem solução

Vamos analisar cada caso em mais detalhes através de alguns exemplos de sistemas de equações lineares  $2 \times 2$ .


# Classificação de Sistemas

## Caso (a) Única solução

$$x_1 + x_2 = 3$$

$$x_1 - x_2 = -1$$

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ -1 \end{bmatrix} \Rightarrow \mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$




# Classificação de Sistemas

## Caso (b) Infinitas Soluções

$$\begin{aligned}x_1 + x_2 &= 1 \\ 2x_1 + 2x_2 &= 2\end{aligned}$$

$$\begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \Rightarrow \mathbf{x} = \begin{bmatrix} 1 - \theta \\ \theta \end{bmatrix}$$




# Classificação de Sistemas

## Caso (c) Sem Solução

$$x_1 + x_2 = 1$$

$$x_1 + x_2 = 4$$

$\Rightarrow \nexists \mathbf{x}$  tal que  $\mathbf{Ax} = \mathbf{b}$



## Existência e unicidade da solução

A equação  $\mathbf{Ax} = \mathbf{b}$  possui uma única solução se e somente se a matriz  $\mathbf{A}$  for não-singular. O Teorema a seguir, caracteriza a não-singularidade da matriz  $\mathbf{A}$ .

### Teorema

*Seja  $\mathbf{A}$  uma matriz quadrada  $n \times n$ . As seguintes afirmações são equivalentes:*

- a)  $\mathbf{A}^{-1}$  existe
- b) *Não existe  $\mathbf{y}$  não-zero tal que  $\mathbf{Ay} = \mathbf{0}$ . Ou seja, a única solução do sistema homogêneo é  $\mathbf{y} = \mathbf{0}$ .*
- c)  $\text{posto}(\mathbf{A}) = n$
- d)  $\det(\mathbf{A}) \neq 0$
- e) *Dado qualquer vetor  $\mathbf{b}$ , existe exatamente um vetor  $\mathbf{x}$  tal que  $\mathbf{Ax} = \mathbf{b}$  (ou  $\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$ ).*

### Prova

*Livro texto de Álgebra Linear.*



## Existência e unicidade da solução

De fato, para os exemplos anteriores, temos

Caso (a)

$$\det \left( \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \right) = -1 - 1 = -2 \neq 0 \Rightarrow \text{OK, solução única}$$

Caso (b)

$$\det \left( \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix} \right) = 2 - 2 = 0$$

Caso (c)

$$\det \left( \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \right) = 1 - 1 = 0$$

## Métodos para solução de sistemas lineares

Iremos estudar agora diversos métodos numéricos para a solução de sistemas de equações lineares. Vamos considerar que  $\mathbf{A}$  é quadrada e não-singular.

Os métodos de solução de sistemas lineares geralmente envolvem a conversão de um sistema quadrado em um sistema triangular que possui a mesma solução que o original.

Inicialmente, vamos estudar como resolver sistemas lineares triangulares inferiores e superiores.

## Sistema triangular inferior

Considere um sistema triangular inferior de ordem  $n$  dado por

$$\begin{bmatrix} l_{11} & 0 & 0 & \dots & 0 \\ l_{21} & l_{22} & 0 & \dots & 0 \\ \vdots & & & \ddots & \\ l_{n1} & l_{n2} & l_{n3} & \dots & l_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

A solução deste sistema é feita através de um procedimento chamado de **substituição** (ou substituições sucessivas):

$$l_{11}x_1 = b_1 \quad \Rightarrow \quad x_1 = \frac{b_1}{l_{11}}$$

$$l_{21}x_1 + l_{22}x_2 = b_2 \quad \Rightarrow \quad x_2 = \frac{b_2 - l_{21}x_1}{l_{22}}$$

$$\vdots$$

$$l_{n1}x_1 + l_{n2}x_2 + \dots + l_{nn}x_n = b_n \quad \Rightarrow \quad x_n = \frac{b_n - l_{n1}x_1 - l_{n2}x_2 - \dots - l_{nn-1}x_{n-1}}{l_{nn}}$$

## Sistema triangular inferior

De forma geral para  $\mathbf{Lx} = \mathbf{b}$  temos

$$x_i = \left( b_i - \sum_{j=1}^{i-1} l_{ij} x_j \right) / l_{ii} \quad i = 1, \dots, n$$

Exemplo

$$\begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & 5 & 0 & 0 \\ 1 & -6 & 8 & 0 \\ -1 & 4 & -3 & 9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 4 \\ 1 \\ 48 \\ 0 \end{bmatrix}$$

Solução

$$\begin{aligned} 2x_1 &= 4 & \Rightarrow x_1 &= 2 \\ 3x_1 + 5x_2 &= 1 & \Rightarrow x_2 &= \frac{1-6}{5} = -1 \\ x_1 - 6x_2 + 8x_3 &= 48 & \Rightarrow x_3 &= \frac{48-2-6}{8} = 5 \\ -x_1 + 4x_2 - 3x_3 + 9x_4 &= 0 & \Rightarrow x_4 &= \frac{2+4+15}{9} = \frac{21}{9} \end{aligned}$$

# Sistema triangular inferior

## Algoritmo

**entrada:**  $\mathbf{L} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{b} \in \mathbb{R}^n$

**saída:**  $\mathbf{x} \in \mathbb{R}^n$

$x(1) = b(1) / L(1,1);$

**para**  $i=2, \dots, n$  **faça**

$s = b(i);$

**para**  $j=1, \dots, i-1$  **faça**

$s = s - L(i,j) * x(j);$

**fim-para**

$x(i) = s/L(i,i);$

**fim-para**

## Sistema triangular superior

O algoritmo análogo para o caso de um sistema triangular superior  $\mathbf{U}\mathbf{x} = \mathbf{b}$  é chamado de **retro-substituição** (ou substituições retroativas).

$$\begin{bmatrix} u_{11} & u_{12} & u_{13} & \dots & u_{1n} \\ 0 & u_{22} & u_{23} & \dots & u_{2n} \\ \vdots & & & \ddots & \\ 0 & 0 & 0 & \dots & u_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

e assim temos

$$u_{nn}x_n = b_n \quad \Rightarrow \quad x_n = \frac{b_n}{u_{nn}}$$

$$u_{n-1,n-1}x_{n-1} + u_{n-1,n}x_n = b_{n-1} \quad \Rightarrow \quad x_{n-1} = \frac{b_{n-1} - u_{n-1,n}x_n}{u_{n-1,n-1}}$$

$$\vdots$$

$$u_{11}x_1 + u_{12}x_2 + \dots + u_{1n}x_n = b_1 \quad \Rightarrow \quad x_1 = \frac{b_1 - u_{12}x_2 - u_{13}x_3 - \dots - u_{1n}x_n}{u_{11}}$$

## Sistema triangular superior

De forma geral para  $\mathbf{U}\mathbf{x} = \mathbf{b}$  temos

$$x_i = \left( b_i - \sum_{j=i+1}^n u_{ij} x_j \right) / u_{ii} \quad i = n, \dots, 1$$

### Exemplo

$$\begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 8 \end{bmatrix}$$

### Solução

$$4x_3 = 8 \quad \Rightarrow \quad x_3 = 2$$

$$x_2 + x_3 = 4 \quad \Rightarrow \quad x_2 = 2$$

$$2x_1 + 4x_2 - 2x_3 = 2 \quad \Rightarrow \quad x_1 = \frac{2-8+4}{2} = -\frac{2}{2} = -1$$

# Sistema triangular superior

## Algoritmo

**entrada:**  $\mathbf{U} \in \mathbb{R}^{n \times n}$ ,  $\mathbf{b} \in \mathbb{R}^n$

**saída:**  $\mathbf{x} \in \mathbb{R}^n$

$x(n) = b(n)/U(n,n);$

**para**  $i=n-1, \dots, 1$  **faça**

$s = b(i);$

**para**  $j=i+1, \dots, n$  **faça**

$s = s - U(i,j) * x(j);$

**fim-para**

$x(i) = s/U(i,i);$

**fim-para**



# Complexidade Computacional

Muitas vezes precisamos medir o custo de execução de um algoritmo. Para isso usualmente definimos uma função de complexidade que pode ser uma medida do tempo para o algoritmo resolver um problema cuja instância de entrada tem tamanho  $n$  (ou medir por exemplo o quanto de memória seria necessário para execução).

A complexidade de um algoritmo para solução de um sistema linear de ordem  $n$  é medida através do número de operações aritméticas como adição, multiplicação e divisão.

Lembrando que

$$\sum_{i=1}^n i = \frac{n(n+1)}{2}$$

# Complexidade Computacional

## Substituição:

Divisão:  $n$

$$\text{Adição: } \sum_{i=2}^n (i-1) = \sum_{i=1}^{n-1} i = \frac{n(n-1)}{2}$$

$$\text{Multiplicação: } \sum_{i=2}^n (i-1) = \sum_{i=1}^{n-1} i = \frac{n(n-1)}{2}$$

No total o algoritmo de substituição para sistemas triangulares inferiores realiza

$$n + \frac{n(n-1)}{2} + \frac{n(n-1)}{2} = n + n^2 - n = n^2$$

operações de ponto flutuante.

# Complexidade Computacional

## Retro-substituição:

Divisão:  $n$

$$\text{Adição: } \sum_{i=1}^{n-1} (n-i) = n(n-1) - \frac{n(n-1)}{2} = \frac{n(n-1)}{2}$$

$$\text{Multiplicação: } \sum_{i=1}^{n-1} (n-i) = n(n-1) - \frac{n(n-1)}{2} = \frac{n(n-1)}{2}$$

No total o algoritmo de retro-substituição para sistemas triangulares superiores realiza

$$n + \frac{n(n-1)}{2} + \frac{n(n-1)}{2} = n + n^2 - n = n^2$$

operações de ponto flutuante.

# Métodos para solução de sistemas lineares

Existem dois tipos de métodos para a solução de sistemas de equações lineares:

- ▶ Métodos diretos
  - ▶ Os métodos diretos são aqueles que conduzem à **solução exata** após um número finito de passos a menos de erros de arredondamento introduzidos pela máquina.
- ▶ Métodos iterativos
  - ▶ São aqueles que se baseiam na construção de **sequências de aproximações**. Em um método iterativo, a cada passo, os valores calculados anteriormente são usados para melhorar a aproximação. É claro que o método só será útil se a sequência de aproximações construídas convergir para uma solução aproximada do sistema.

## Eliminação de Gauss

O primeiro método direto que iremos estudar é o método da eliminação de Gauss. A idéia fundamental do método é transformar a matriz **A** em uma matriz triangular superior introduzindo zeros abaixo da diagonal principal, primeiro na coluna 1, depois na coluna 2 e assim por diante.

$$\begin{bmatrix} x & x & x & x \\ x & x & x & x \\ x & x & x & x \\ x & x & x & x \end{bmatrix} \rightarrow \begin{bmatrix} x & x & x & x \\ 0 & x & x & x \\ 0 & x & x & x \\ 0 & x & x & x \end{bmatrix} \rightarrow \begin{bmatrix} x & x & x & x \\ 0 & x & x & x \\ 0 & 0 & x & x \\ 0 & 0 & x & x \end{bmatrix} \rightarrow \begin{bmatrix} x & x & x & x \\ 0 & x & x & x \\ 0 & 0 & x & x \\ 0 & 0 & 0 & x \end{bmatrix}$$

Por fim, usa-se a **retro-substituição** para obter a solução do sistema triangular superior obtido ao final dessa etapa de eliminação.

# Eliminação de Gauss

Na eliminação de Gauss, as operações efetuadas para se obter a matriz triangular superior são tais que a matriz triangular obtida possui a mesma solução que o sistema original.

## Definição (Sistema equivalente)

*Dois sistemas de equações lineares são equivalentes quando possuem o mesmo vetor solução.*

Um sistema pode ser transformado em um outro sistema equivalente utilizando as seguintes operações elementares:

- ▶ trocar a ordem de duas equações
- ▶ multiplicar uma equação por uma constante não-nula
- ▶ somar um múltiplo de uma equação à outra

# Eliminação de Gauss

## Exemplo

$$3x_1 + 5x_2 = 9$$

$$6x_1 + 7x_2 = 4$$



Podemos subtrair da linha 2 um múltiplo da linha 1, isto é

$$L'_2 = L_2 - 2L_1$$

Efetuada esta operação obtemos o sistema equivalente

$$3x_1 + 5x_2 = 9$$

$$-3x_2 = -14$$



# Eliminação de Gauss

Vamos primeiro estudar um exemplo simples para posteriormente generalizar a idéia.

## Exemplo

Seja o sistema

$$\begin{aligned}x_1 + x_3 &= 0 \\x_1 + x_2 &= 1 \\2x_1 + 3x_2 + x_3 &= 1\end{aligned}\qquad \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 2 & 3 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$

## Solução

Como podemos eliminar os coeficientes abaixo da diagonal principal na primeira coluna?

$$\begin{aligned}L'_2 &= L_2 - L_1 \\L'_3 &= L_3 - 2L_1\end{aligned}\qquad \left[ \begin{array}{ccc|c} 1 & 0 & 1 & 0 \\ \mathbf{0} & \mathbf{1} & -\mathbf{1} & \mathbf{1} \\ \mathbf{0} & \mathbf{3} & -\mathbf{1} & \mathbf{1} \end{array} \right]$$



# Eliminação de Gauss

## Exemplo - (cont.)

Precisamos agora de eliminar os coeficientes abaixo da diagonal na segunda coluna ( $a_{32}$ ). Como?

$$L_3'' = L_3' - 3L_2' \qquad \left[ \begin{array}{ccc|c} 1 & 0 & 1 & 0 \\ 0 & 1 & -1 & 1 \\ 0 & \mathbf{0} & \mathbf{2} & \mathbf{-2} \end{array} \right]$$

Agora podemos usar a retro-substituição para encontrar facilmente a solução deste sistema:

$$\begin{aligned} 2x_3 &= -2 &\Rightarrow & x_3 = -1 \\ x_2 - x_3 &= 1 &\Rightarrow & x_2 = 1 + x_3 = 1 - 1 = 0 \\ x_1 + x_3 &= 0 &\Rightarrow & x_1 = -x_3 = 1 \end{aligned}$$

Encontramos assim a solução:  $x^T = [1 \quad 0 \quad -1]$

# Conteúdo

- ▶ Aula passada
  - ▶ Conceitos fundamentais
  - ▶ Sistemas triangulares
  - ▶ Eliminação de Gauss
- ▶ Aula de hoje
  - ▶ Eliminação de Gauss
  - ▶ Estratégias de Pivoteamento
  - ▶ Decomposição LU

## Revisitando a Eliminação de Gauss

Resolver o seguinte sistema

$$\begin{bmatrix} \mathbf{2} & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 5 \\ -2 \\ 9 \end{bmatrix}$$

Passo 1

$$m_{21} = \frac{a_{21}}{a_{11}} = 4/2 = 2 \quad \Rightarrow \quad L'_2 = L_2 - 2L_1$$

$$m_{31} = \frac{a_{31}}{a_{11}} = -2/2 = -1 \quad \Rightarrow \quad L'_3 = L_3 + L_1$$

$$\left[ \begin{array}{ccc|c} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ 0 & 8 & 3 & 14 \end{array} \right]$$

## Revisitando a Eliminação de Gauss

Passo 2

$$\left[ \begin{array}{ccc|c} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ 0 & 8 & 3 & 14 \end{array} \right]$$

$$m_{32} = \frac{a_{32}}{a_{22}} = 8 / -8 = -1 \quad \Rightarrow \quad L_3'' = L_3' + L_2'$$

$$\left[ \begin{array}{ccc|c} 2 & 1 & 1 & 5 \\ 0 & -8 & -2 & -12 \\ 0 & 0 & 1 & 2 \end{array} \right]$$

Próxima etapa: resolver o sistema triangular superior obtido usando o algoritmo de **retro-substituição**.

# Eliminação de Gauss

De forma geral

$$\left[ \begin{array}{ccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} & b_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} & b_n \end{array} \right]$$

**Passo 1 (k=1):** eliminamos os elementos abaixo da diagonal principal na primeira coluna. Suponha que  $a_{11} \neq 0$ . Então:

$$m_{21} = a_{21}/a_{11}$$

$$m_{31} = a_{31}/a_{11}$$

$$\vdots$$

$$m_{n1} = a_{n1}/a_{11}$$

ou seja

$$m_{i1} = a_{i1}/a_{11}, \quad i = 2 : n$$

Notação:  $i = 2 : n \Leftrightarrow i = 2, 3, \dots, n$

## Eliminação de Gauss

Agora, multiplicamos a 1ª equação por  $m_{i1}$  e subtraímos da  $i$ -ésima equação, isto é

$$\begin{aligned}\text{Para } i = 2 : n \quad a_{ij}^{(1)} &= a_{ij}^{(0)} - m_{i1} a_{1j}^{(0)} \\ b_i^{(1)} &= b_i^{(0)} - m_{i1} b_1^{(0)}, \quad j = 1 : n\end{aligned}$$

Observe que não alteramos a primeira linha, pois  $i = 2 : n$ , logo esta permanece inalterada:

$$a_{1j}^{(1)} = a_{1j}^{(0)} = a_{1j}, \quad b_1^{(1)} = b_1^{(0)} = b_1$$

Após essa etapa zeramos todos os elementos abaixo da diagonal principal na 1ª coluna.

$$\left[ \begin{array}{ccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1n} & b_1 \\ \mathbf{0} & \mathbf{a_{22}^1} & \mathbf{a_{23}^1} & \dots & \mathbf{a_{2n}^1} & \mathbf{b_2^1} \\ \mathbf{0} & \mathbf{a_{32}^1} & \mathbf{a_{33}^1} & \dots & \mathbf{a_{3n}^1} & \mathbf{b_3^1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \mathbf{0} & \mathbf{a_{n2}^1} & \mathbf{a_{n3}^1} & \dots & \mathbf{a_{nn}^1} & \mathbf{b_n^1} \end{array} \right]$$

## Eliminação de Gauss

**Passo 2 (k=2):** consiste em introduzir zeros abaixo da diagonal principal na 2ª coluna. Suponha  $a_{22} \neq 0$ . Definimos

$$m_{i2} = a_{i2}/a_{22}, \quad i = 3 : n$$

e assim

$$\begin{aligned} \text{para } i = 3 : n \quad a_{ij}^{(2)} &= a_{ij}^{(1)} - m_{i2} a_{2j}^{(1)} \\ b_i^{(2)} &= b_i^{(1)} - m_{i2} b_1^{(2)}, \quad j = 2 : n \end{aligned}$$

o que resulta em

$$\left[ \begin{array}{ccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1n} & b_1 \\ 0 & a_{22}^1 & a_{23}^1 & \dots & a_{2n}^1 & b_2^1 \\ 0 & \mathbf{0} & \mathbf{a_{33}^2} & \dots & \mathbf{a_{3n}^2} & \mathbf{b_3^2} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \mathbf{0} & \mathbf{a_{n3}^2} & \dots & \mathbf{a_{nn}^2} & \mathbf{b_n^2} \end{array} \right]$$

# Eliminação de Gauss

**Passo 3, Passo 4, ...**

**Passo k:** Considerando  $a_{kk} \neq 0$ , temos

$$m_{ik} = a_{ik}/a_{kk}, \quad i = k + 1 : n$$

e assim fazemos

$$\begin{aligned} \text{para } i = k + 1 : n \quad a_{ij}^{(k)} &= a_{ij}^{(k-1)} - m_{ik} a_{kj}^{(k-1)} \\ b_i^{(k)} &= b_i^{(k-1)} - m_{ik} b_k^{(k-1)}, \quad j = k : n \end{aligned}$$

Observe novamente que não alteramos as linhas de 1 a  $k$ .



## Eliminação de Gauss

No processo de eliminação os elementos  $a_{11}, a_{22}^{(1)}, a_{33}^{(2)}, \dots, a_{kk}^{(k-1)}$  que aparecem na diagonal da matriz  $\mathbf{A}$  são chamados de pivôs.

Se os pivôs não se anulam, isto é, se  $a_{kk} \neq 0, k = 1 : n$ , durante o processo, então a eliminação procede com sucesso e por fim chegamos ao seguinte sistema triangular superior

$$\left[ \begin{array}{cccccc|c} a_{11} & a_{12} & a_{13} & \dots & a_{1n-1} & a_{1n} & b_1 \\ 0 & a_{22}^1 & a_{23}^1 & \dots & a_{2n-1}^1 & a_{2n}^1 & b_2^1 \\ 0 & 0 & a_{33}^2 & \dots & a_{3n-1}^2 & a_{3n}^2 & b_3^2 \\ \vdots & \vdots & \vdots & \ddots & & \vdots & \vdots \\ 0 & 0 & 0 & \dots & \mathbf{0} & \mathbf{a}_{nn}^{n-1} & \mathbf{b}_n^{n-1} \end{array} \right]$$

Em seguida resolvemos esse sistema usando retro substituição.

# Eliminação de Gauss

## Algoritmo

**entrada:** matriz  $\mathbf{A} \in \mathbb{R}^{n \times n}$ , vetor  $\mathbf{b} \in \mathbb{R}^n$

**saída:** vetor solução  $\mathbf{x} \in \mathbb{R}^n$

**para**  $k = 1 : n - 1$  **faça**

**para**  $i = k + 1 : n$  **faça**

$m = A(i,k) / A(k,k);$

**para**  $j = k + 1 : n$  **faça**

$A(i,j) = A(i,j) - m * A(k,j);$

**fim-para**

$b(i) = b(i) - m * b(k);$

**fim-para**

**fim-para**

$\mathbf{x} = \text{retroSubstituicao}(\mathbf{A}, \mathbf{b});$

retorna  $\mathbf{x};$

# Eliminação de Gauss

## Complexidade Computacional

Novamente vamos contabilizar o número de operações aritméticas de ponto flutuante que são realizadas pelo algoritmo.

Para contar o número de operações realizadas na eliminação de Gauss, vamos dividir o processo nas seguintes etapas:

- (1)  $\mathbf{A} \rightarrow \mathbf{U}$ : o processo de transformar a matriz  $\mathbf{A}$  em uma matriz triangular superior  $\mathbf{U}$
- (2)  $\mathbf{b} \rightarrow \mathbf{g}$ : modificações no vetor  $\mathbf{b}$
- (3) Resolver  $\mathbf{U}\mathbf{x} = \mathbf{g}$  usando retro-substituição
  - ▶ Já vimos que o número de operações deste algoritmo é  $n^2$

No que segue iremos usar

$$\sum_{i=1}^n i = \frac{n(n+1)}{2}$$

$$\sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}$$

# Eliminação de Gauss

## Complexidade Computacional

### (1) $A \rightarrow U$

#### ► Divisões

$$\begin{aligned}\sum_{k=1}^{n-1} \left( \sum_{i=k+1}^n 1 \right) &= \sum_{k=1}^{n-1} (n - k) \\&= n(n-1) - \sum_{k=1}^{n-1} k \\&= n(n-1) - \frac{n(n-1)}{2} \\&= \frac{n(n-1)}{2}\end{aligned}$$

# Eliminação de Gauss

## Complexidade Computacional

### (1) $\mathbf{A} \rightarrow \mathbf{U}$

#### ► Adições

$$\begin{aligned}\sum_{k=1}^{n-1} \sum_{i=k+1}^n \left( \sum_{j=k+1}^n 1 \right) &= \sum_{k=1}^{n-1} \left( \sum_{i=k+1}^n (n-k) \right) \\&= \sum_{k=1}^{n-1} (n-k)(n-k) \\&= \sum_{k=1}^{n-1} (n^2 - 2kn + k^2) \\&= n^2(n-1) - 2n \frac{n(n-1)}{2} + \frac{(n-1)(n-1+1)(2n-2+1)}{6} \\&= \frac{n(n-1)(2n-1)}{6}\end{aligned}$$

#### ► Multiplicações

$$\frac{n(n-1)(2n-1)}{6}$$

# Eliminação de Gauss

## Complexidade Computacional

### (2) $\mathbf{b} \rightarrow \mathbf{g}$

#### ► Adições

$$\begin{aligned}\sum_{k=1}^{n-1} \left( \sum_{i=k+1}^n 1 \right) &= \sum_{k=1}^{n-1} (n - k) \\&= n(n-1) - \sum_{k=1}^{n-1} k \\&= n(n-1) - \frac{n(n-1)}{2} \\&= \frac{n(n-1)}{2}\end{aligned}$$

#### ► Multiplicações

$$\frac{n(n-1)}{2}$$

# Eliminação de Gauss

## Complexidade Computacional

(Total)

Em cada etapa temos

$$(1) \frac{2}{3}n^3 - \frac{n^2}{2} - \frac{n}{6}$$

$$(2) n^2 - n$$

Assim nas etapas (1) e (2) temos um total de  $\frac{2}{3}n^3 + \frac{n^2}{2} - \frac{7}{6}n$ .  
Considerando que na etapa de retro-substituição (3) temos  $n^2$  operações, no total o algoritmo de eliminação de Gauss realiza um total de

$$\underbrace{\frac{2n^3}{3} + \frac{n^2}{2} - \frac{7n}{6}}_{\text{eliminação}} + \underbrace{n^2}_{\text{retro-substituição}} = \frac{2n^3}{3} + \frac{3n^2}{2} - \frac{7n}{6}$$

# Eliminação de Gauss

Para um valor de  $n$  muito grande, o algoritmo realiza aproximadamente  $\frac{2}{3}n^3$  operações de ponto flutuante.

## Exemplo

Se um sistema linear tem tamanho  $n = 100$ , então:

- ▶ resolver o sistema triangular:  $100^2 = 10\,000$  operações
- ▶ eliminação de gauss: 681 550 operações

Ou seja, nesse exemplo, a eliminação de Gauss é  $68\times$  mais lenta que a solução de um sistema triangular !!!



## Eliminação de Gauss

**Mas, e se** na etapa  $k$  da eliminação de Gauss, o pivô for zero? Isso significa que  $a_{kk} = 0$ , e assim, teríamos

$$m_{ik} = \frac{a_{ik}}{a_{kk}} \Rightarrow \text{divisão por zero!}$$

Nesse caso, se um pivô for zero, o processo de eliminação tem que parar, ou temporariamente ou permanentemente.

**O sistema pode ou não ser singular.**

Se o sistema for singular, i.e,  $\det(\mathbf{A}) = 0$ , e portanto como vimos o sistema não possui uma única solução.

Veremos agora um caso que a matriz não é singular e podemos resolver esse problema.

## Estratégia de Pivoteamento

Vamos ilustrar a idéia do pivoteamento através de um exemplo.  
Considere a seguinte matriz.

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 2 & 5 \\ 4 & 6 & 8 \end{bmatrix}$$

Vamos proceder com a eliminação de Gauss.

$$\begin{aligned} m_{21} &= 2, & a_{2j}^1 &= a_{2j}^0 - 2 a_{1j}^0 \\ m_{31} &= 4, & a_{3j}^1 &= a_{3j}^0 - 4 a_{1j}^0, & j &= 1 : 3 \end{aligned}$$

Então obtemos

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 3 \\ 0 & 2 & 4 \end{bmatrix}$$

## Estratégia de Pivoteamento

No próximo passo, o pivô é  $a_{22}$  e usamos ele para calcular  $m_{32}$ .  
Entretanto

$$m_{32} = \frac{a_{32}}{a_{22}} = \frac{2}{0}$$

Divisão por zero! E agora, o que podemos fazer?

Podemos realizar uma operação elementar de troca de linhas. Como vimos este tipo de operação quando realizado em um sistema, não altera a solução. Sendo assim, vamos trocar as linhas 2 e 3.

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 3 \\ 0 & 2 & 4 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 1 & 1 \\ 0 & 2 & 4 \\ 0 & 0 & 3 \end{bmatrix}$$

E assim chegamos a um sistema triangular superior, cuja solução pode ser obtida usando a retro-substituição.

# Estratégia de Pivoteamento

A estratégia de pivoteamento é importante pois:

- ▶ **evita a propagação de erros numéricos**
- ▶ nos fornece meios de evitar problemas durante a eliminação de Gauss quando o **pivô**  $a_{kk}$  no passo  $k$  é **igual a zero** e precisamos calcular o multiplicador

$$m_{ik} = \frac{a_{ik}}{a_{kk}}$$

Assim, através da troca de linhas, podemos encontrar uma linha de tal forma que o novo pivô é não-zero, permitindo que a eliminação de Gauss continue até obter uma matriz triangular superior.

Temos duas possibilidades:

- ▶ pivoteamento parcial
- ▶ pivoteamento total

## Pivoteamento Parcial

No pivoteamento parcial, em cada passo  $k$ , **o pivô é escolhido como o maior elemento em módulo** abaixo de  $a_{kk}$  (inclusive), isto é

Encontrar  $r$  tal que:  $|a_{rk}| = \max |a_{ik}|, k \leq i \leq n$

Feita a escolha do pivô, trocamos as linhas  $r$  e  $k$  e o algoritmo procede.

Isso evita a propagação de erros numéricos, pois:

- ▶ O pivoteamento parcial garante que

$$|m_{ik}| \leq 1$$

- ▶ Se  $a_{kk}$  for muito pequeno, consequentemente  $m_{ik}$  será muito grande. Dessa forma, após a multiplicação por  $m_{ik}$  podemos ampliar erros de arredondamento envolvidos no processo.
- ▶ Também evitamos o erro que pode ser causado quando somamos um número pequeno com um número grande.

# Pivoteamento Parcial

## Exemplo

Aplique a eliminação de Gauss com pivoteamento parcial no seguinte sistema:

$$\left[ \begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 4 & 9 & -3 & 8 \\ -2 & -3 & 7 & 10 \end{array} \right]$$

A cada passo  $k$ :

- ▶ encontrar o pivô do passo  $k$
- ▶ se necessário, trocar as linhas
- ▶ calcular multiplicador  $m_{ik}$
- ▶ para  $i = k + 1 : n$ , calcular

$$\begin{aligned} a_{ij}^{(k)} &= a_{ij}^{(k-1)} - m_{ik} a_{kj}^{(k-1)} \\ b_i^{(k)} &= b_i^{(k-1)} - m_{ik} b_k^{(k-1)}, \quad j = k : n \end{aligned}$$

# Pivoteamento Parcial

## Exemplo - (cont.)

### Passo 1

Escolha do pivô:  $\max \{2, 4, 2\} = 4$ . Trocar as linhas 1 e 2.

$$\left[ \begin{array}{ccc|c} 2 & 4 & -2 & 2 \\ 4 & 9 & -3 & 8 \\ -2 & -3 & 7 & 10 \end{array} \right] \Rightarrow \left[ \begin{array}{ccc|c} 4 & 9 & -3 & 8 \\ 2 & 4 & -2 & 2 \\ -2 & -3 & 7 & 10 \end{array} \right]$$

$$m_{21} = 2/4 = 1/2 \quad \Rightarrow \quad a_{2j}^1 = a_{2j}^0 - \frac{1}{2}a_{1j}^0$$

$$m_{31} = -2/4 = -1/2 \quad \Rightarrow \quad a_{3j}^1 = a_{3j}^0 + \frac{1}{2}a_{1j}^0, \quad j = 1 : 3$$

$$\left[ \begin{array}{ccc|c} 4 & 9 & -3 & 8 \\ 0 & -\frac{1}{2} & -\frac{1}{2} & -2 \\ 0 & \frac{3}{2} & \frac{11}{2} & 14 \end{array} \right]$$

# Pivoteamento Parcial

## Exemplo - (cont.)

### Passo 2

Escolha do pivô:  $\max \left\{ \frac{1}{2}, \frac{3}{2} \right\} = \frac{3}{2}$ . Trocar as linhas 2 e 3.

$$\left[ \begin{array}{ccc|c} 4 & 9 & -3 & 8 \\ 0 & -\frac{1}{2} & -\frac{1}{2} & -2 \\ 0 & \frac{3}{2} & \frac{11}{2} & 14 \end{array} \right] \Rightarrow \left[ \begin{array}{ccc|c} 4 & 9 & -3 & 8 \\ 0 & \frac{3}{2} & \frac{11}{2} & 14 \\ 0 & -\frac{1}{2} & -\frac{1}{2} & -2 \end{array} \right]$$

$$m_{32} = -\frac{1}{2} \frac{2}{3} = -\frac{1}{3} \Rightarrow a_{3j}^2 = a_{3j}^1 + \frac{1}{3} a_{2j}^1, \quad j = 2 : 3$$

$$\left[ \begin{array}{ccc|c} 4 & 9 & -3 & 8 \\ 0 & \frac{3}{2} & \frac{11}{2} & 14 \\ 0 & 0 & \frac{4}{3} & \frac{8}{3} \end{array} \right]$$



# Pivoteamento Parcial

Exemplo - (cont.)

**Retro-substituição**

$$\left[ \begin{array}{ccc|c} 4 & 9 & -3 & 8 \\ 0 & \frac{3}{2} & \frac{11}{2} & 14 \\ 0 & 0 & \frac{4}{3} & \frac{8}{3} \end{array} \right]$$

$$\frac{4}{3}x_3 = \frac{8}{3} \Rightarrow \boxed{x_3 = 2}$$

$$\frac{3}{2}x_2 + 2\frac{11}{2} = 14 \Rightarrow \boxed{x_2 = 2}$$

$$4x_1 + 9(2) - 3(2) = 8 \Rightarrow \boxed{x_1 = -1}$$

Portanto a solução é  $\mathbf{x}^T = [-1, 2, 2]$ .



# Pivoteamento Parcial

## Exemplo (efeitos numéricos)

Considere o seguinte sistema:

$$\begin{bmatrix} 0.0001 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

Usando um sistema de ponto flutuante  $F(10, 3, -10, 10)$  (sistema decimal com 3 dígitos na mantissa), com arredondamento, encontre a solução do sistema usando eliminação de Gauss sem pivoteamento.

## Solução

Temos que

$$m_{21} = \frac{1}{0.0001} = 10000 \quad \Rightarrow \quad L'_2 = L_2 - 10000L_1$$

## Pivoteamento Parcial

Solução (efeitos numéricos) - Cont.

$$\left[ \begin{array}{cc|c} 0.0001 & 1 & 1 \\ 0 & -\mathbf{10000^*} & -\mathbf{10000^{**}} \end{array} \right]$$

Note que (\*) foi obtido como

$$\begin{aligned} 1 - 10000 \times 1 &= 0.00001 \times 10^5 - 0.10000 \times 10^5 \\ &= 0.09999 \times 10^5 \\ &= (\text{arredondando}) = 0.100 \times 10^5 \end{aligned}$$

e de forma análoga para (\*\*), temos

$$\begin{aligned} 2 - 10000 \times 1 &= 0.00001 \times 10^5 - 0.10000 \times 10^5 \\ &= 0.09998 \times 10^5 \\ &= (\text{arredondando}) = 0.100 \times 10^5 \end{aligned}$$

## Pivoteamento Parcial

### Solução (efeitos numéricos) - Cont.

Por fim, aplicando a retrossubstituição obtemos uma solução errada, devido aos erros de aritmética em ponto flutuante cometidos em (\*) e (\*\*) durante a soma/subtração de números muito pequenos com números muito grandes.

$$\text{Solução obtida} \rightarrow \mathbf{x}^T = \begin{bmatrix} 0 & 1 \end{bmatrix}$$

A solução exata é dada por

$$\text{Solução exata} \rightarrow \mathbf{x}^T = \begin{bmatrix} 1.00010001 & 0.99989999 \end{bmatrix}$$



## Pivoteamento Parcial

Se durante o processo de eliminação com pivoteamento parcial no passo  $k$  não houver nenhuma entrada **não-zero** abaixo de  $a_{kk}$  na coluna  $k$ , como no exemplo abaixo (depois do passo 1):

$$\begin{bmatrix} x & x & x & x & x \\ 0 & \mathbf{0} & x & x & x \\ 0 & \mathbf{0} & x & x & x \\ 0 & \mathbf{0} & x & x & x \\ 0 & \mathbf{0} & x & x & x \end{bmatrix}$$

então:

- ▶ podemos seguir para o próximo passo e completar a eliminação
- ▶ entretanto a matriz triangular superior  $\mathbf{U}$  resultante do processo possui um zero na diagonal principal, o que implica que

$$\det \mathbf{U} = 0 \quad \Rightarrow \quad \mathbf{U} \text{ é singular} \quad \Rightarrow \quad \mathbf{A} \text{ é singular}$$

# Pivoteamento Parcial

## Algoritmo

```
para  $k = 1 : n - 1$  faça  
     $w = |A(k,k)|$ ;  
    para  $j = k : n$  faça  
        se  $|A(j,k)| > w$  então  
             $w = |A(j,k)|$ ;  
             $r = j$ ;  
        fim-se  
    fim-para  
    trocaLinhas(k,r);  
    para  $i = k + 1 : n$  faça  
         $m = A(i,k) / A(k,k)$ ;  
        para  $j = k + 1 : n$  faça  
             $A(i,j) = A(i,j) - m * A(k,j)$  ;  
        fim-para  
         $b(i) = b(i) - m * b(k)$  ;  
    fim-para  
fim-para
```

## Pivoteamento Total

Na estratégia de pivoteamento total, o elemento escolhido como pivô é o maior elemento em módulo que ainda atua no processo de eliminação, isto é:

Encontrar  $r$  e  $s$  tais que:  $|a_{rs}| = \max |a_{ij}|, k \leq i, j \leq n$


Feita a escolha do pivô é preciso trocar as linhas  $k$  e  $r$  e as colunas  $k$  e  $s$ .

Observe que a troca de colunas afeta a ordem das incógnitas do vetor  $\mathbf{x}$ .


Em geral o pivoteamento parcial é satisfatório, e o pivoteamento total não é muito usado devido ao alto esforço computacional requerido na busca pelo maior elemento em módulo no resto da matriz.

# Estratégias de Pivoteamento

## Pivoteamento Parcial



## Pivoteamento Total





## Decomposição LU

Uma matriz quadrada pode ser escrita como o produto de duas matrizes **L** e **U**, onde

- ▶ **L** é uma matriz triangular inferior unitária (com elementos da diagonal principal igual a 1)
- ▶ **U** é uma matriz triangular superior

Ou seja, a matriz pode ser escrita como

$$\mathbf{A} = \mathbf{LU}$$

Dessa forma para resolver o sistema linear  $\mathbf{Ax} = \mathbf{b}$  usamos **A** em sua forma decomposta, isto é

$$\mathbf{Ax} = \mathbf{b} \quad \Rightarrow \quad \mathbf{LUx} = \mathbf{b}$$

Então definimos

$$\mathbf{Ux} = \mathbf{y}$$

## Decomposição LU

Assim para resolver

$$\mathbf{L} \underbrace{\mathbf{U}\mathbf{x}}_{\mathbf{y}} = \mathbf{b}$$

fazemos

$$\mathbf{L}\mathbf{y} = \mathbf{b} \quad \Rightarrow \quad \mathbf{U}\mathbf{x} = \mathbf{y}$$

isto é, temos os seguintes passos:

1. Como  $\mathbf{L}$  é triangular inferior podemos resolver  $\mathbf{L}\mathbf{y} = \mathbf{b}$  facilmente usando o algoritmo de **substituição**. Assim encontramos o vetor  $\mathbf{y}$ .
2. Em seguida substituímos  $\mathbf{y}$  no sistema  $\mathbf{U}\mathbf{x} = \mathbf{y}$ . Como  $\mathbf{U}$  é uma matriz triangular superior, podemos resolver este sistema usando o algoritmo da **retro-substituição** para encontrar a solução  $\mathbf{x}$ .

Vamos ver agora em que condições podemos decompor uma matriz  $\mathbf{A}$  na forma  $\mathbf{LU}$ .

# Decomposição LU

## Teorema (LU)

*Sejam  $\mathbf{A} = (a_{ij})$  uma matriz quadrada de ordem  $n$  e  $\mathbf{A}_k$  o menor principal, constituído das  $k$  primeiras linhas e  $k$  primeiras colunas de  $\mathbf{A}$ .*

*Assumimos que  $\det(\mathbf{A}_k) \neq 0$  para  $k = 1, 2, \dots, n - 1$ .*

*Então existe:*

- ▶ *uma única matriz triangular inferior  $\mathbf{L} = (l_{ij})$  com  $l_{ii} = 1, i = 1 : n$*
- ▶ *uma única matriz triangular superior  $\mathbf{U} = (u_{ij})$*

*tal que  $\mathbf{A} = \mathbf{LU}$ .*

*Além disso,  $\det(\mathbf{A}) = u_{11}u_{22} \dots u_{nn}$ .*

## Prova (Neide, Página 123)

*Usa indução matemática.*

# Decomposição LU

## Prova

(i) Para  $n = 1$  temos

$$a_{11} = 1 \quad a_{11} = 1 \quad u_{11} \Rightarrow u_{11} = a_{11}, l_{11} = 1$$

e ainda  $\det(\mathbf{A}) = u_{11}$ .

(ii) Assumimos que o teorema é verdadeiro para  $n = k - 1$ , ou seja, que toda matriz de ordem  $(k - 1)$  é decomponível no produto  $\mathbf{LU}$ .

(iii) Vamos mostrar que podemos decompor  $\mathbf{A}$  para  $n = k$ . Seja  $\mathbf{A}$  de ordem  $k$ , escrita da forma

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{k-1} & \mathbf{r} \\ \mathbf{s} & a_{kk} \end{bmatrix} \quad (1)$$

Por hipótese de indução temos que

$$\mathbf{A}_{k-1} = \mathbf{L}_{k-1} \mathbf{U}_{k-1} \quad (2)$$

# Decomposição LU

## Prova (cont.)

Usando (2) temos

$$\mathbf{A} = \mathbf{L}\mathbf{U} \Rightarrow \mathbf{L} = \begin{bmatrix} \mathbf{L}_{k-1} & \mathbf{0} \\ \mathbf{m} & 1 \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} \mathbf{U}_{k-1} & \mathbf{p} \\ \mathbf{0} & u_{kk} \end{bmatrix}$$

onde  $\mathbf{m}$ ,  $\mathbf{p}$  e  $u_{kk}$  são desconhecidos. Efetuando o produto temos

$$\mathbf{L}\mathbf{U} = \begin{bmatrix} \mathbf{L}_{k-1}\mathbf{U}_{k-1} & \mathbf{L}_{k-1}\mathbf{p} \\ \mathbf{m}\mathbf{U}_{k-1} & \mathbf{m}\mathbf{p} + u_{kk} \end{bmatrix} \quad (3)$$

Comparando (1) e (3)

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{k-1} & \mathbf{r} \\ \mathbf{s} & a_{kk} \end{bmatrix} = \begin{bmatrix} \mathbf{L}_{k-1}\mathbf{U}_{k-1} & \mathbf{L}_{k-1}\mathbf{p} \\ \mathbf{m}\mathbf{U}_{k-1} & \mathbf{m}\mathbf{p} + u_{kk} \end{bmatrix}$$

# Decomposição LU

## Prova (cont.)

*Assim*

$$\mathbf{A}_{k-1} = \mathbf{L}_{k-1} \mathbf{U}_{k-1}$$

$$\mathbf{r} = \mathbf{L}_{k-1} \mathbf{p}$$

$$\mathbf{s} = \mathbf{m} \mathbf{U}_{k-1}$$

$$\mathbf{m} \mathbf{p} + u_{kk} = a_{kk}$$

*Observe que*

- ▶ *pela hip. de indução  $\mathbf{L}_{k-1}$  e  $\mathbf{U}_{k-1}$  são unicamente determinadas*
- ▶ *e ainda,  $\mathbf{L}_{k-1}$  e  $\mathbf{U}_{k-1}$  não são singulares, caso contrário  $\mathbf{A}_{k-1}$  também seria, contrariando a hipótese*

# Decomposição LU

## Prova (cont.)

*Portanto*

$$\mathbf{r} = \mathbf{L}_{k-1}\mathbf{p} \quad \Rightarrow \quad \mathbf{p} = \mathbf{L}_{k-1}^{-1}\mathbf{r}$$

$$\mathbf{s} = \mathbf{m}\mathbf{U}_{k-1} \quad \Rightarrow \quad \mathbf{m} = \mathbf{s}\mathbf{U}_{k-1}^{-1}$$

$$\mathbf{m}\mathbf{p} + u_{kk} = a_{kk} \quad \Rightarrow \quad u_{kk} = a_{kk} - \mathbf{m}\mathbf{p}$$

*Ou seja,  $\mathbf{m}$ ,  $\mathbf{p}$  e  $u_{kk}$  são determinados unicamente nesta ordem e, portanto,  $\mathbf{L}$  e  $\mathbf{U}$  são determinados unicamente.*

*Finalmente*

$$\det(\mathbf{A}) = \det(\mathbf{L})\det(\mathbf{U}) = 1 \det(\mathbf{U}) = u_{11}u_{22} \dots u_{nn}$$



# Decomposição LU

## Obtenção das matrizes **L** e **U**

Podemos obter as matrizes **L** e **U** aplicando a definição de produto e igualdade de matrizes, ou seja, impondo que **A** seja igual a **LU**, onde **L** é triangular inferior unitária e **U** triangular superior. Então

$$\mathbf{LU} = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ l_{21} & 1 & 0 & \dots & 0 \\ l_{31} & l_{32} & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & 1 & 0 \\ l_{n1} & l_{n2} & l_{n3} & \dots & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & u_{13} & \dots & u_{1n} \\ 0 & u_{22} & u_{23} & \dots & u_{2n} \\ 0 & 0 & u_{33} & \dots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & u_{nn} \end{bmatrix}$$

Vamos obter os elementos de **L** e **U** da seguinte forma:

- ▶ 1ª linha de **U**
- ▶ 1ª coluna de **L**
- ▶ 2ª linha de **U**
- ▶ 2ª coluna de **L**
- ▶ ...



# Decomposição LU

Obtenção das matrizes **L** e **U**

**1<sup>a</sup> linha de U**

$$a_{11} = 1 \ u_{11} \Rightarrow u_{11} = a_{11}$$

$$a_{12} = 1 \ u_{12} \Rightarrow u_{12} = a_{12}$$

...

$$a_{1n} = 1 \ u_{1n} \Rightarrow u_{1n} = a_{1n}$$

**1<sup>a</sup> coluna de L**

$$a_{21} = l_{21} \ u_{11} \Rightarrow l_{21} = \frac{a_{21}}{u_{11}}$$

$$a_{31} = l_{31} \ u_{11} \Rightarrow l_{31} = \frac{a_{31}}{u_{11}}$$

...

$$a_{n1} = l_{n1} \ u_{11} \Rightarrow l_{n1} = \frac{a_{n1}}{u_{11}}$$

# Decomposição LU

Obtenção das matrizes **L** e **U**

**2ª linha de U**

$$a_{22} = l_{21}u_{12} + 1 u_{22} \Rightarrow u_{22} = a_{22} - l_{21}u_{12}$$

$$a_{23} = l_{21}u_{13} + 1 u_{23} \Rightarrow u_{23} = a_{23} - l_{21}u_{13}$$

...

$$a_{2n} = l_{21}u_{1n} + 1 u_{2n} \Rightarrow u_{2n} = a_{2n} - l_{21}u_{1n}$$

**2ª coluna de L**

$$a_{32} = l_{31}u_{12} + l_{32}u_{22} \Rightarrow l_{32} = \frac{a_{32} - l_{31}u_{12}}{u_{22}}$$

$$a_{42} = l_{41}u_{12} + l_{42}u_{22} \Rightarrow l_{42} = \frac{a_{42} - l_{41}u_{12}}{u_{22}}$$

...

$$a_{n2} = l_{n1}u_{12} + l_{n2}u_{22} \Rightarrow l_{n2} = \frac{a_{n2} - l_{n1}u_{12}}{u_{22}}$$

# Decomposição LU

## Obtenção das matrizes $\mathbf{L}$ e $\mathbf{U}$

De forma geral temos

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}, \quad i \leq j$$

$$l_{ij} = \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj} \right) / u_{jj}, \quad i > j$$

# Decomposição LU

Obtenção das matrizes **L** e **U**

**para**  $i = 1 : n$  **faça**

**para**  $j = i : n$  **faça**

$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj} ;$

**fim-para**

**para**  $j = i + 1 : n$  **faça**

$l_{ij} = \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj} \right) / u_{jj} ;$

**fim-para**

**fim-para**

**Observação:** na prática as matrizes **L** e **U** nunca são criadas e alocadas explicitamente. O que fazemos é sobrescrever as entradas da matriz original **A** com as entradas de **L** e **U**.

# Decomposição LU

## Via eliminação de Gauss

O método da eliminação de Gauss pode ser interpretado como um método para obtenção das matrizes  $\mathbf{L}$  e  $\mathbf{U}$ . No processo da EG no passo 1, eliminamos as entradas abaixo de  $a_{11}$  na coluna 1 da matriz fazendo

$$\begin{aligned}\text{Para } i = 2 : n \quad m_{i1} &= \frac{a_{i1}}{a_{11}} \\ a_{ij}^1 &= a_{ij}^0 - m_{i1} a_{1j}^0 \\ b_i^1 &= b_i^0 - m_{i1} b_1^0, \quad j = 1 : n\end{aligned}$$

essa operação é equivalente a multiplicar  $(\mathbf{A}|\mathbf{b})^0$  por uma matriz  $\mathbf{M}_1$ , para obter  $(\mathbf{A}|\mathbf{b})^1$ , onde

$$\mathbf{M}_1 = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ -m_{21} & 1 & 0 & \dots & 0 \\ -m_{31} & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -m_{n1} & 0 & \dots & 0 & 1 \end{bmatrix}$$

# Decomposição LU

Assim

$$\begin{aligned}\mathbf{M}_1(\mathbf{A}|\mathbf{b})^0 &= \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ -m_{21} & 1 & 0 & \dots & 0 \\ -m_{31} & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -m_{n1} & 0 & \dots & 0 & 1 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ a_{31} & a_{32} & \dots & a_{3n} & b_3 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} & b_n \end{bmatrix} \\ &= \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ 0 & a_{22}^1 & \dots & a_{2n}^1 & b_2^1 \\ 0 & a_{32}^1 & \dots & a_{3n}^1 & b_3^1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & a_{n2}^1 & \dots & a_{nn}^1 & b_n^1 \end{bmatrix} = (\mathbf{A}|\mathbf{b})^1\end{aligned}$$

## Decomposição LU

No passo seguinte temos

$$(\mathbf{A}|\mathbf{b})^2 = \mathbf{M}_2(\mathbf{A}|\mathbf{b})^1$$

$$\begin{aligned}\mathbf{M}_2(\mathbf{A}|\mathbf{b})^1 &= \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & -m_{32} & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & 0 \\ 0 & -m_{n2} & \dots & 0 & 1 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ 0 & a_{22}^1 & \dots & a_{2n}^1 & b_2^1 \\ 0 & a_{32}^1 & \dots & a_{3n}^1 & b_3^1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & a_{n2}^1 & \dots & a_{nn}^1 & b_n^1 \end{bmatrix} \\ &= \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ 0 & a_{22}^1 & \dots & a_{2n}^1 & b_2^1 \\ 0 & 0 & \dots & a_{3n}^2 & b_3^2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & a_{nn}^2 & b_n^2 \end{bmatrix} = (\mathbf{A}|\mathbf{b})^2\end{aligned}$$

## Decomposição LU

Procedemos dessa forma, até que por fim temos

$$\begin{aligned}(\mathbf{A}|\mathbf{b})^{(n-1)} &= \mathbf{M}_{n-1}(\mathbf{A}|\mathbf{b})^{(n-2)} \\ &= \dots = \underbrace{\mathbf{M}_{n-1}\mathbf{M}_{n-2}\dots\mathbf{M}_2\mathbf{M}_1}_{\mathbf{M}}(\mathbf{A}|\mathbf{b})^{(0)}\end{aligned}$$

Deste modo temos

$$\mathbf{A}^{(n-1)} = \mathbf{M}\mathbf{A} = \mathbf{U}$$

onde  $\mathbf{U}$  é a matriz triangular superior da decomposição LU. Como  $\mathbf{M}$  é um produto de matrizes não-singulares,  $\mathbf{M}$  é inversível, isto é,

$$\begin{aligned}\mathbf{M} &= \mathbf{M}_{n-1}\mathbf{M}_{n-2}\dots\mathbf{M}_2\mathbf{M}_1 \\ \mathbf{M}^{-1} &= \mathbf{M}_1^{-1}\mathbf{M}_2^{-1}\dots\mathbf{M}_{n-2}^{-1}\mathbf{M}_{n-1}^{-1}\end{aligned}$$

Portanto

$$\mathbf{M}\mathbf{A} = \mathbf{U} \quad \Rightarrow \quad \mathbf{A} = \underbrace{\mathbf{M}^{-1}}_{\mathbf{L}}\mathbf{U}$$



## Decomposição LU

$$\mathbf{MA} = \mathbf{U} \quad \Rightarrow \quad \mathbf{A} = \underbrace{\mathbf{M}^{-1}}_{\mathbf{L}} \mathbf{U}$$

onde

$$\mathbf{M}^{-1} = \mathbf{L} = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ m_{21} & 1 & 0 & \dots & 0 \\ m_{31} & m_{32} & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & 0 \\ m_{n1} & m_{n2} & m_{n3} & \dots & 1 \end{bmatrix}$$

é a matriz triangular inferior da decomposição LU.

# Decomposição LU

## Exemplo 1

Decomponha a matriz  $\mathbf{A}$  dada abaixo nos fatores  $\mathbf{L}$  e  $\mathbf{U}$ , usando a eliminação de Gauss.

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{bmatrix}$$

## Solução do Exemplo 1

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 & 0 \\ 4 & 3 & 3 & 1 \\ 8 & 7 & 9 & 5 \\ 6 & 7 & 9 & 8 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 4 & 3 & 1 & 0 \\ 3 & 4 & 1 & 1 \end{bmatrix}}_{\mathbf{L}} \underbrace{\begin{bmatrix} 2 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 2 \end{bmatrix}}_{\mathbf{U}}$$

# Decomposição LU

## Exemplo 2

Resolva o seguinte sistema linear:

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 3 & -2 \\ 1 & -2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix}$$

## Solução do Exemplo 2

$$\mathbf{A} = \mathbf{LU} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 1 & 4 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & -1 \\ 0 & -1 & 0 \\ 0 & 0 & 2 \end{bmatrix}, \quad \mathbf{x}^* = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

# Decomposição LU

## Cálculo do Determinante

Veremos como utilizar a decomposição  $\mathbf{A} = \mathbf{L}\mathbf{U}$  para calcular o determinante da matriz.

$$\det(\mathbf{A}) = \det(\mathbf{L})\det(\mathbf{U})$$

O determinante de uma matriz triangular é dado pelo produto dos elementos da diagonal principal, isto é

$$\det(\mathbf{L}) = 1$$

$$\det(\mathbf{U}) = u_{11}u_{22}u_{33} \dots u_{nn}$$

Portanto

$$\det(\mathbf{A}) = \det(\mathbf{L}) \det(\mathbf{U})$$

$$= 1 \det(\mathbf{U})$$

$$= u_{11}u_{22}u_{33} \dots u_{nn}$$

# Decomposição LU

## Cálculo do Determinante

### Exemplo 2

Para o exemplo anterior, temos

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 1 & 4 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & -1 \\ 0 & -1 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

Portanto o determinante é

$$\det(\mathbf{A}) = 1 (-1) 2 = -2$$



## Decomposição LU com Pivoteamento Parcial

Vamos estudar agora o uso de pivoteamento parcial para a decomposição LU.

Para definir o que significa, de forma matricial, a troca de duas linhas de uma matriz, iremos apresentar o conceito de matrizes de permutação.

Uma matriz de permutação é uma matriz obtida a partir da matriz identidade através de uma reordenação de suas linhas, isto é

$$\mathbf{P} = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

Portanto se  $\mathbf{P}$  é uma matriz de permutação e  $\mathbf{A}$  uma matriz qualquer, então

- ▶  $\mathbf{PA}$  é uma versão da matriz  $\mathbf{A}$  com as linhas permutadas
- ▶  $\mathbf{AP}$  é uma versão da matriz  $\mathbf{A}$  com as colunas permutadas

## Decomposição LU com Pivoteamento Parcial

Na prática (implementação) uma matriz de permutação  $\mathbf{P}$  de dimensão  $n \times n$  nunca é armazenada explicitamente. É muito mais eficiente representar  $\mathbf{P}$  por um vetor  $p$  de valores inteiros de tamanho  $n$ .

Uma forma de implementar isso é fazer com que  $p[k]$  seja o índice da coluna que tem apenas um "1" na  $k$ -ésima linha de  $\mathbf{P}$ . Para o exemplo anterior

$$p = [3 \quad 2 \quad 1]$$

Para aplicar a estratégia de pivoteamento parcial nos exercícios, basta trocar efetivamente as linhas da matriz. Vejamos um exemplo.

## Decomposição LU com Pivoteamento Parcial

Para resolver  $\mathbf{Ax} = \mathbf{b}$ , segue-se o procedimento:

- ▶ Calcular  $\mathbf{P}$ ,  $\mathbf{L}$  e  $\mathbf{U}$  tal que  $\mathbf{PA} = \mathbf{LU}$
- ▶ Atualizar vetor  $\mathbf{b} = \mathbf{Pb}$
- ▶ Resolver  $\mathbf{Ly} = \mathbf{b}$
- ▶ Resolver  $\mathbf{Ux} = \mathbf{y}$

Dicas para calcular  $\mathbf{L}$  e  $\mathbf{U}$  via eliminação de Gauss com pivoteamento:

- ▶ se trocar linhas, atualizar o vetor  $\mathbf{p}$ ;
- ▶ guardar os multiplicadores da eliminação de Gauss na posição que foi zerada, ao invés de colocar os zeros.



# Decomposição LU com Pivoteamento Parcial

## Exemplo 3

Resolver o sistema linear abaixo usando a decomposição LU com pivoteamento parcial.

$$\begin{bmatrix} 3 & -4 & 1 \\ 1 & 2 & 2 \\ 4 & 0 & -3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 9 \\ 3 \\ -2 \end{bmatrix}$$

## Solução do Exemplo 3

$$\mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ \frac{3}{4} & 1 & 0 \\ \frac{1}{4} & -\frac{1}{2} & 1 \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} 4 & 0 & -3 \\ 0 & -4 & \frac{13}{4} \\ 0 & 0 & \frac{35}{8} \end{bmatrix}, \quad p = [3 \quad 1 \quad 2]$$

$$\mathbf{x}^T = [1 \quad -1 \quad 2]$$

# Decomposição LU com Pivoteamento Parcial

## Solução do Exemplo 3 - Passo a passo

### Etapas 1

$$\begin{bmatrix} 3 & -4 & 1 \\ 1 & 2 & 2 \\ 4 & 0 & -3 \end{bmatrix}, \quad p = [1 \quad 2 \quad 3]$$

Troca as linhas 1 e 3 e atualiza vetor  $p$

$$\begin{bmatrix} 4 & 0 & -3 \\ 1 & 2 & 2 \\ 3 & -4 & 1 \end{bmatrix}, \quad p = [3 \quad 2 \quad 1]$$

Elimina e guarda os multiplicadores nas suas posições (em azul):

$$\begin{bmatrix} 4 & 0 & -3 \\ \text{1/4} & 2 & 11/4 \\ \text{3/4} & -4 & 13/4 \end{bmatrix}, \quad p = [3 \quad 2 \quad 1]$$

# Decomposição LU com Pivoteamento Parcial

## Solução do Exemplo 3 - Passo a passo

### Etapa 2

$$\begin{bmatrix} 4 & 0 & -3 \\ 1/4 & 2 & 11/4 \\ 3/4 & -4 & 13/4 \end{bmatrix}, \quad p = [3 \quad 2 \quad 1]$$

Troca as linhas 2 e 3 e atualiza vetor  $p$

$$\begin{bmatrix} 4 & 0 & -3 \\ 3/4 & -4 & 13/4 \\ 1/4 & 2 & 11/4 \end{bmatrix}, \quad p = [3 \quad 1 \quad 2]$$

Elimina e guarda os multiplicadores nas suas posições (em azul):

$$\begin{bmatrix} 4 & 0 & -3 \\ 3/4 & -4 & 13/4 \\ 1/4 & -1/2 & 35/8 \end{bmatrix}, \quad p = [3 \quad 1 \quad 2]$$

# Decomposição LU com Pivoteamento Parcial

## Solução do Exemplo 3 - Passo a passo

Resultado

$$\begin{bmatrix} 4 & 0 & -3 \\ 3/4 & -4 & 13/4 \\ 1/4 & -1/2 & 35/8 \end{bmatrix}, \quad p = [3 \quad 1 \quad 2]$$

Decomposição  $\mathbf{PA} = \mathbf{LU}$ :

$$\mathbf{P} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} 3 & -4 & 1 \\ 1 & 2 & 2 \\ 4 & 0 & -3 \end{bmatrix}$$

$$\mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ 3/4 & 1 & 0 \\ 1/4 & -1/2 & 1 \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} 4 & 0 & -3 \\ 0 & -4 & 13/4 \\ 0 & 0 & 35/8 \end{bmatrix}$$

# Decomposição LU com Pivoteamento Parcial

## Solução do Exemplo 3

Para resolver  $PAx = Pb \Rightarrow L U x = Pb$ , define-se  $Ux = y$  e então:

1. Resolva  $Ly = Pb$
2. Resolva  $Ux = y$

Procedendo desta forma, chega-se em

$$\mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ \frac{3}{4} & 1 & 0 \\ \frac{1}{4} & -\frac{1}{2} & 1 \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} 4 & 0 & -3 \\ 0 & -4 & \frac{13}{4} \\ 0 & 0 & \frac{35}{8} \end{bmatrix}, \quad p = [3 \quad 1 \quad 2]$$

$$\mathbf{x}^T = [1 \quad -1 \quad 2]$$



# Conteúdo

- ▶ Aula passada
  - ▶ Eliminação de Gauss
  - ▶ Estratégias de Pivoteamento
  - ▶ Decomposição **LU**
- ▶ Aula de hoje
  - ▶ Decomposição de Cholesky
  - ▶ Decomposição **LDL<sup>T</sup>**
  - ▶ Cálculo da Matriz Inversa
  - ▶ Sistema com Matriz Singular

## Revisitando algumas definições

### Definição (Matriz Simétrica)

Uma matriz real  $\mathbf{A} \in \mathbb{R}^{n \times n}$  é simétrica se possui as mesmas entradas acima e abaixo da diagonal principal, isto é, se

$$a_{ij} = a_{ji}, \quad \forall i, j$$

Portanto  $\mathbf{A} = \mathbf{A}^T$ .

Tais matrizes satisfazem a seguinte relação

$$\mathbf{x}^T \mathbf{A} \mathbf{y} = \mathbf{y}^T \mathbf{A} \mathbf{x}, \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$$

### Definição (Matriz Positiva Definida)

Se a matriz  $\mathbf{A}$  é simétrica, então é dita ser positiva definida se

$$\mathbf{x}^T \mathbf{A} \mathbf{x} > 0, \quad \forall \mathbf{x} \neq 0$$

## Revisitando algumas definições

**Matriz Positiva Definida:** de imediato verifica-se que se  $\mathbf{A}$  é não singular, caso contrário haveria um  $\mathbf{x}$  diferente de zero tal que  $\mathbf{Ax} = \mathbf{0}$ .

Além disso, escolhendo vetores escritos na forma

$$\mathbf{x}^T = [x_1 \quad x_2 \quad \dots \quad x_k \quad 0 \quad 0 \quad \dots \quad 0]$$

podemos verificar que todas as matrizes menores principais ( $\mathbf{A}_k$ ) são positivas definidas, portanto não singular ( $\det(\mathbf{A}_k) \neq 0$ ) e consequentemente podemos decompor  $\mathbf{A}$  na forma  $\mathbf{A} = \mathbf{LU}$ .

Na prática muitas matrizes que surgem em aplicações de engenharias e ciências são simétricas e positiva definidas, devido a leis físicas que estão por trás da origem dessas matrizes.



## Testes para matrizes positivas definidas

1. Critério de Sylvester: uma matriz  $\mathbf{A} \in \mathbb{R}^{n \times n}$  é positiva definida, se e somente se

$$\det(\mathbf{A}_k) > 0, \quad k = 1, 2, \dots, n$$

onde  $\mathbf{A}_k$  é a matriz menor principal de ordem  $k$  (a matriz  $k \times k$  formada pelas  $k$  primeiras linhas e pelas  $k$  primeiras colunas).

2. Se realizarmos a eliminação de Gauss *sem troca de linha ou coluna na matriz  $\mathbf{A}$* , podemos dizer que  $\mathbf{A}$  é positiva definida, se e somente se, **todos os pivôs forem positivos**.

### Exemplo

Verifique se as seguintes matrizes são positivas definidas:

$$\mathbf{A} = \begin{bmatrix} 4 & 1 & 2 \\ 1 & 3 & 0 \\ 2 & 0 & 5 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & 4 & 2 \\ 4 & 3 & 0 \\ 2 & 0 & 5 \end{bmatrix}, \quad \mathbf{K} = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

## Decomposição de Cholesky

Quando a matriz do sistema linear é simétrica, podemos simplificar os cálculos da decomposição LU levando em conta a simetria da matriz. Essa é a idéia do método de Cholesky.

Se  $\mathbf{A}$  é simétrica positiva definida, pelo critério de Sylvester temos que

$$\det(\mathbf{A}_k) > 0$$

portanto, todos os menores principais são não singulares e consequentemente (Teorema LU), a matriz pode ser escrita como  $\mathbf{A} = \mathbf{LU}$ .

Se  $\mathbf{A}$  é simétrica, então  $\mathbf{A} = \mathbf{A}^T$ . Logo

$$\mathbf{LU} = \mathbf{A} = \mathbf{A}^T = (\mathbf{LU})^T = \mathbf{U}^T \mathbf{L}^T$$

# Decomposição de Cholesky

Assim

$$\mathbf{L}\mathbf{U} = \mathbf{U}^T\mathbf{L}^T$$

$$\mathbf{L}^{-1}\mathbf{L}\mathbf{U} = \mathbf{L}^{-1}\mathbf{U}^T\mathbf{L}^T$$

$$\mathbf{U} = \mathbf{L}^{-1}\mathbf{U}^T\mathbf{L}^T$$

$$\mathbf{U}(\mathbf{L}^T)^{-1} = \mathbf{L}^{-1}\mathbf{U}^T\mathbf{L}^T(\mathbf{L}^T)^{-1}$$

$$\mathbf{U}(\mathbf{L}^T)^{-1} = \mathbf{L}^{-1}\mathbf{U}^T$$

Temos que

$$\underbrace{\mathbf{U}(\mathbf{L}^T)^{-1}}_{\text{triangular superior}} = \underbrace{\mathbf{L}^{-1}\mathbf{U}^T}_{\text{triangular inferior}}$$

Portanto, essa igualdade só pode ser uma matriz diagonal!

Seja

$$\mathbf{D} = \mathbf{U}(\mathbf{L}^T)^{-1} \quad (\text{ou } \mathbf{D} = \mathbf{L}^{-1}\mathbf{U}^T)$$

## Decomposição de Cholesky

Seja

$$\mathbf{D} = \mathbf{U}(\mathbf{L}^T)^{-1} \quad (\text{ou } \mathbf{D} = \mathbf{L}^{-1}\mathbf{U}^T)$$

então

$$\mathbf{DL}^T = \mathbf{U} \quad (\text{ou } \mathbf{U}^T = \mathbf{LD})$$

Sendo assim temos que

$$\mathbf{A} = \mathbf{LDL}^T = \mathbf{U}^T\mathbf{DU} \tag{4}$$

E assim o determinante pode ser calculado como

$$\begin{aligned} \det(\mathbf{A}) &= \det(\mathbf{L})\det(\mathbf{D})\det(\mathbf{L}^T) = 1 \cdot (d_{11}d_{22} \dots d_{nn}) \cdot 1 \\ &= d_{11}d_{22} \dots d_{nn} \end{aligned}$$

## Decomposição de Cholesky

Assim de (4), como todos  $d_{ii} > 0$ , podemos escrever

$$\mathbf{A} = \mathbf{L}\mathbf{D}\mathbf{L}^T = \mathbf{L}(\mathbf{D})^{1/2}(\mathbf{D})^{1/2}\mathbf{L}^T = \mathbf{G}\mathbf{G}^T$$

onde

$$\begin{aligned}\mathbf{G} &= \mathbf{L}(\mathbf{D})^{1/2} \\ \mathbf{G}^T &= (\mathbf{D})^{1/2}\mathbf{L}^T\end{aligned}$$

A decomposição de Cholesky é um caso especial da fatoração LU aplicada para matrizes simétricas e positiva definida (SPD) e sua decomposição pode ser obtida a partir de

$$\mathbf{A} = \mathbf{G}\mathbf{G}^T$$

onde  $\mathbf{G}$  é uma matriz triangular inferior tal que

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} g_{11} & 0 & \dots & 0 \\ g_{21} & g_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ g_{n1} & g_{n2} & \dots & g_{nn} \end{bmatrix} \begin{bmatrix} g_{11} & g_{21} & \dots & g_{n1} \\ 0 & g_{22} & \dots & g_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & g_{nn} \end{bmatrix}$$

## Decomposição de Cholesky

Pelo produto e igualdade de matrizes podemos obter os elementos de  $\mathbf{G}$ . Elementos da diagonal principal:

$$a_{11} = g_{11}^2$$

$$a_{22} = g_{21}^2 + g_{22}^2$$

$$\vdots$$

$$a_{nn} = g_{n1}^2 + g_{n2}^2 + \dots + g_{nn}^2$$

de forma geral

$$g_{ii} = \sqrt{a_{ii} - \sum_{k=1}^{i-1} g_{ik}^2}, \quad i = 1 : n \quad (5)$$

## Decomposição de Cholesky

Para os elementos fora da diagonal principal, temos

$$a_{21} = g_{21}g_{11}$$

$$a_{31} = g_{31}g_{11}$$

$$\vdots$$

$$a_{n1} = g_{n1}g_{11}$$

$$a_{32} = g_{31}g_{21} + g_{32}g_{22}$$

$$a_{42} = g_{41}g_{21} + g_{42}g_{22}$$

$$\vdots$$

$$a_{n2} = g_{n1}g_{21} + g_{n2}g_{22}$$

de forma geral

$$g_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} g_{ik}g_{jk}}{g_{jj}}, \quad i = j+1 : n, \quad j = 1 : n \quad (6)$$

# Decomposição de Cholesky

## Algoritmo

Observando as equações (5) e (6), vemos que podemos calcular os elementos de  $\mathbf{G}$  da seguinte forma:

- ▶ a cada passo  $j$ :
  - ▶ calcula-se termo da diagonal principal  $g_{jj}$
  - ▶ calcula-se termos da coluna  $j$  abaixo da diagonal principal isto é  $g_{ij}$  com  $i = j + 1 : n$

**para**  $j = 1 : n$  **faça**

$$g_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2} ;$$

**para**  $i = j + 1 : n$  **faça**

$$g_{ij} = \left( a_{ij} - \sum_{k=1}^{j-1} g_{ik} g_{jk} \right) / g_{jj} ;$$

**fim-para**

**fim-para**



# Decomposição de Cholesky

## Observações:

- ▶ Se  $\mathbf{A}$  é SPD, então a aplicação do método de Cholesky requer menos operações de ponto flutuante do que a decomposição LU.
- ▶ Como  $\mathbf{A}$  é positiva definida, isto garante que só teremos raízes quadradas de números positivos, isto é, os termos  $a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2$  são sempre maiores do que zero.
  - ▶ Exemplo do caso  $2 \times 2$
- ▶ Caso o algoritmo falhe, podemos concluir que  $\mathbf{A}$  não é simétrica e positiva definida.
- ▶ Determinante

$$\det(\mathbf{A}) = \det(\mathbf{G})\det(\mathbf{G}^T) = \det(\mathbf{G})^2 = (g_{11}g_{22} \dots g_{nn})^2$$

## Decomposição de Cholesky

Podemos usar a decomposição de Cholesky para encontrar a solução de  $\mathbf{Ax} = \mathbf{b}$  da seguinte forma:

1. Determinar a decomposição

$$\mathbf{A} = \mathbf{G}\mathbf{G}^T$$

então

$$\mathbf{G} \underbrace{\mathbf{G}^T \mathbf{x}}_{\mathbf{y}} = \mathbf{b}$$

2. Resolver  $\mathbf{G}\mathbf{y} = \mathbf{b}$ , usando substituição
3. Resolver  $\mathbf{G}^T \mathbf{x} = \mathbf{y}$ , retro-substituição

# Decomposição de Cholesky

## Exemplo

Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 4 & -2 & 2 \\ -2 & 10 & -7 \\ 2 & -7 & 30 \end{bmatrix}$$

- a) Verificar se  $\mathbf{A}$  satisfaz as condições da decomposição de Cholesky
- b) Decompor  $\mathbf{A}$  em  $\mathbf{G}\mathbf{G}^T$
- c) Calcular o determinante
- d) Resolver o sistema  $\mathbf{A}\mathbf{x} = \mathbf{b}$  com  $\mathbf{b} = \begin{bmatrix} 8 \\ 11 \\ -31 \end{bmatrix}$

# Decomposição de Cholesky

## Solução do Exemplo

a)  $\mathbf{A}$  é simétrica e positiva definida

$$\det(\mathbf{A}_1) = 4, \quad \det(\mathbf{A}_2) = 36, \quad \det(\mathbf{A}_3) = 900$$

b) A decomposição é

$$\mathbf{A} = \underbrace{\begin{bmatrix} 2 & 0 & 0 \\ -1 & 3 & 0 \\ 1 & -2 & 5 \end{bmatrix}}_{\mathbf{G}} \underbrace{\begin{bmatrix} 2 & -1 & 1 \\ 0 & 3 & -2 \\ 0 & 0 & 5 \end{bmatrix}}_{\mathbf{G}^T}$$

c)  $\det(\mathbf{A}) = (2 \cdot 3 \cdot 5)^2 = 30^2 = 900$

d)  $\mathbf{x} = \begin{bmatrix} 3 \\ 1 \\ -1 \end{bmatrix}$



## Decomposição de Cholesky

Podemos usar as fórmulas (5) e (6) para calcular os elementos da matriz  $\mathbf{G}$  da decomposição, mas também podemos proceder de outra forma.

Idéia:

- ▶ Decompor  $\mathbf{A} = \mathbf{L}\mathbf{U}$  via eliminação de Gauss
- ▶ Como  $\mathbf{U} = \mathbf{D}\mathbf{L}^T$ , calcular  $\mathbf{D}$
- ▶ E assim calcular  $\mathbf{G} = \mathbf{L}\mathbf{D}^{1/2}$

### Exemplo

A partir da decomposição LU da matriz  $\mathbf{A}$  do exemplo anterior, obtenha  $\mathbf{G}$ .

$$\mathbf{A} = \begin{bmatrix} 4 & -2 & 2 \\ -2 & 10 & -7 \\ 2 & -7 & 30 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ -\frac{1}{2} & 1 & 0 \\ \frac{1}{2} & -\frac{2}{3} & 1 \end{bmatrix}}_{\mathbf{L}} \underbrace{\begin{bmatrix} 4 & -2 & 2 \\ 0 & 9 & -6 \\ 0 & 0 & 25 \end{bmatrix}}_{\mathbf{U}}$$

# Decomposição de Cholesky

## Exercício

Mostrar que, se o sistema linear  $\mathbf{Ax} = \mathbf{b}$ , onde  $\mathbf{A}$  é não singular, é transformado no sistema linear equivalente

$$\mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b}$$

então esse último sistema linear pode sempre ser resolvido pelo método de Cholesky (isto é  $\mathbf{B} = \mathbf{A}^T \mathbf{A}$  satisfaz as condições para a aplicação do método).

Aplicar a técnica anterior para encontrar a solução do seguinte sistema linear:

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \\ 2 \end{bmatrix}$$

# Decomposição de Cholesky

## Exercício

Dicas:

- ▶ Mostre que  $\mathbf{B}$  satisfaz as condições da decomposição de Cholesky
- ▶ Irá precisar de usar

$$\begin{aligned}\|\mathbf{x}\| &= \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} \\ \|\mathbf{x}\|^2 &= x_1^2 + x_2^2 + \dots + x_n^2 = \mathbf{x}^T \mathbf{x}\end{aligned}$$

## Decomposição $\mathbf{LDL}^T$

Como vimos anteriormente também podemos decompor  $\mathbf{A}$  na forma  $\mathbf{A} = \mathbf{LDL}^T$ , onde  $\mathbf{L}$  é uma matriz triangular inferior unitária e  $\mathbf{D}$  é uma matriz diagonal.

De forma análoga ao que fizemos para a decomposição de Cholesky, podemos determinar os elementos da decomposição da seguinte forma:

$$d_{jj} = a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 d_{kk} , \quad j = 1 : n$$
$$l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_{kk} l_{jk}}{d_{jj}} \quad j = 1 : n - 1, \quad i = j + 1 : n$$



# Decomposição $\mathbf{LDL}^T$

## Solução de sistema linear

A solução do sistema linear  $\mathbf{Ax} = \mathbf{b}$  é dada por

$$\begin{aligned}\mathbf{Ax} = \mathbf{b} &\Rightarrow \mathbf{LD} \underbrace{\mathbf{L}^T \mathbf{x}}_{\mathbf{y}} = \mathbf{b} \\ &\Rightarrow \mathbf{L} \underbrace{\mathbf{Dy}}_{\mathbf{w}} = \mathbf{b}\end{aligned}$$

e assim temos os seguintes passos para a solução do sistema:

1.  $\mathbf{Lw} = \mathbf{b}$
2.  $\mathbf{Dy} = \mathbf{w}$
3.  $\mathbf{L}^T \mathbf{x} = \mathbf{y}$

Cálculo do determinante

$$\begin{aligned}\det(\mathbf{A}) &= \det(\mathbf{L})\det(\mathbf{D})\det(\mathbf{L}^T) \\ &= 1 \cdot \det(\mathbf{D}) \cdot 1 = d_{11}d_{22} \dots d_{nn}\end{aligned}$$

# Decomposição $\mathbf{LDL}^T$

## Algoritmo

**para**  $j = 1 : n$  **faça**

$$d_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 d_{kk}} ;$$

**para**  $i = j + 1 : n$  **faça**

$$l_{ij} = \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_{kk} l_{jk} \right) / d_{jj} ;$$

**fim-para**

**fim-para**

# Decomposição $LDL^T$

## Algoritmo

```
det = 1 ;  
para  $j = 1 : n$  faça  
    soma = 0 ;  
    para  $k = 1 : j - 1$  faça  
        soma = soma +  $A(j,k) * A(j,k) * A(k,k)$  ;  
    fim-para  
     $A(j,j) = A(j,j) - soma$  ;  
     $r = 1 / A(j,j)$  ;  
    det = det *  $A(j,j)$  ;  
    para  $i = j + 1 : n$  faça  
        soma = 0 ;  
        para  $k = 1 : j - 1$  faça  
            soma = soma +  $A(i,k) * A(k,k) * A(j,k)$  ;  
        fim-para  
         $A(i,j) = (A(i,j) - soma) * r$  ;  
    fim-para  
fim-para
```

## Cálculo da Matriz Inversa

Iremos descrever como calcular a matriz inversa através da decomposição LU. Sejam  $\mathbf{A}$  uma matriz de dimensão  $n$ , não singular ( $\det(\mathbf{A}) \neq 0$ ) e  $\mathbf{A}^{-1}$  a matriz inversa de  $\mathbf{A}$ . Vamos escrever a matriz inversa como:

$$\mathbf{A}^{-1} = \left[ \begin{array}{c|c|c|c} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \end{array} \right]$$

Seja ainda  $\mathbf{e}_j$  a coluna  $j$  da matriz identidade. Por exemplo,  $\mathbf{e}_2 = [0 \ 1 \ 0 \ \dots \ 0]$ ,  $\mathbf{e}_n = [0 \ 0 \ 0 \ \dots \ 1]$ . Resolvendo o seguinte sistema linear

$$\mathbf{A}\mathbf{v}_1 = \mathbf{e}_1$$

encontramos a primeira coluna  $\mathbf{v}_1$  da matriz inversa de  $\mathbf{A}$ . Repetindo o procedimento para cada coluna temos

$$\mathbf{A}\mathbf{v}_j = \mathbf{e}_j, \quad j = 1 : n \tag{7}$$

## Cálculo da Matriz Inversa

Agora basta usar algum dos métodos que vimos para resolver os sistemas lineares da equação (7).

### 1. Decomposição LU

$$\mathbf{LU}\mathbf{v}_j = \mathbf{e}_j, \quad j = 1 : n$$

Basta fatorar a matriz na forma LU uma única vez, e com os fatores resolver os seguintes sistemas

$$\mathbf{L}\mathbf{y}_j = \mathbf{e}_j$$

$$\mathbf{U}\mathbf{v}_j = \mathbf{y}_j$$

### 2. Se a matriz for SPD, podemos usar decomposição de Cholesky

$$\mathbf{G}\mathbf{G}^T\mathbf{v}_j = \mathbf{e}_j \quad \Rightarrow \quad (1) \mathbf{G}\mathbf{y}_j = \mathbf{e}_j, \quad (2) \mathbf{G}^T\mathbf{v}_j = \mathbf{y}_j$$

# Cálculo da Matriz Inversa

## 3. Eliminação de Gauss.

Montar

$$[ \mathbf{A} \mid \mathbf{I} ]$$

e efetuar a eliminação de Gauss de uma vez só. Assim obtemos

$$[ \mathbf{U} \mid \mathbf{T} ]$$

onde  $\mathbf{T}$  é uma matriz triangular inferior. Em seguida dado que temos  $\mathbf{U}$  triangular superior, basta resolver a seguinte sequência de sistemas

$$\mathbf{U}\mathbf{v}_j = \mathbf{t}_j$$

onde  $\mathbf{t}_j$  é a coluna  $j$  da matriz  $\mathbf{T}$ .

# Cálculo da Matriz Inversa

## Exemplo

Calcular a inversa da seguinte matriz

$$\mathbf{A} = \begin{bmatrix} 4 & 1 & -6 \\ 3 & 2 & -6 \\ 3 & 1 & -5 \end{bmatrix}$$

Assim temos

$$\left[ \begin{array}{ccc|ccc} 4 & 1 & -6 & 1 & 0 & 0 \\ 3 & 2 & -6 & 0 & 1 & 0 \\ 3 & 1 & -5 & 0 & 0 & 1 \end{array} \right]$$

Efetuada a eliminação de Gauss obtemos

$$\left[ \begin{array}{ccc|ccc} 4 & 1 & -6 & 1 & 0 & 0 \\ 0 & 5/4 & -3/2 & -3/4 & 1 & 0 \\ 0 & 0 & -1/5 & -3/5 & -1/5 & 1 \end{array} \right]$$

# Cálculo da Matriz Inversa

## Exemplo

Agora basta resolver

$$\begin{bmatrix} 4 & 1 & -6 \\ 0 & 5/4 & -3/2 \\ 0 & 0 & -1/5 \end{bmatrix} \mathbf{v}_1 = \begin{bmatrix} 1 \\ -3/4 \\ -3/5 \end{bmatrix}$$

$$\begin{bmatrix} 4 & 1 & -6 \\ 0 & 5/4 & -3/2 \\ 0 & 0 & -1/5 \end{bmatrix} \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ -1/5 \end{bmatrix}$$

$$\begin{bmatrix} 4 & 1 & -6 \\ 0 & 5/4 & -3/2 \\ 0 & 0 & -1/5 \end{bmatrix} \mathbf{v}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$



# Conteúdo

- ▶ Aula passada
  - ▶ Decomposição de Cholesky
  - ▶ Decomposição  $\mathbf{LDL}^T$
  - ▶ Cálculo da Matriz Inversa
- ▶ Aula de hoje
  - ▶ Métodos Iterativos
    - ▶ Método de Jacobi
    - ▶ Método de Gauss-Seidel
    - ▶ Método SOR

# Métodos Iterativos

O sistema de equações lineares  $\mathbf{Ax} = \mathbf{b}$  pode ser resolvido por um processo que gera a partir de um vetor inicial  $\mathbf{x}^{(0)}$  uma sequência de vetores  $\mathbf{x}^{(1)}$ ,  $\mathbf{x}^{(2)}$ ,  $\mathbf{x}^{(3)}$ , ... que deve convergir para a solução.

Existem muitos métodos iterativos para a solução de sistemas lineares, entretanto só iremos estudar os chamados **métodos iterativos estacionários**.

Algumas perguntas importantes são:

- ▶ Como construir a sequência  $\{\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots\}$ ?
- ▶  $\mathbf{x}^{(k)} \rightarrow \mathbf{x}^*$ ?
- ▶ Quais são as condições para convergência?
- ▶ Como saber se  $\mathbf{x}^{(k)}$  está próximo de  $\mathbf{x}^*$ ?
- ▶ Critério de parada?

## Métodos Iterativos

Um método iterativo escrito na forma

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{c} \quad (8)$$

é dito *estacionário* quando a matriz  $\mathbf{B}$  for fixa durante o processo iterativo.

Veremos como construir a matriz  $\mathbf{B}$  para cada um dos métodos que iremos estudar: **Jacobi**, **Gauss-Seidel** e **Sobre-relaxação (SOR)**.

Antes, é preciso rever alguns conceitos como norma de vetores e matrizes, os quais serão importantes no desenvolvimento do critério de parada e na análise de convergência dos métodos.

# Normas de Vetores e Matrizes

Para discutir o erro envolvido nas aproximações é preciso associar a cada vetor e matriz um valor escalar não negativo que de alguma forma mede sua magnitude. As normas para vetores mais comuns são:

- ▶ Norma euclideana (ou norma  $L_2$ )

$$\|\mathbf{x}\|_2 = (x_1^2 + x_2^2 + \dots + x_n^2)^{1/2}$$

- ▶ Norma infinito (ou norma do máximo)

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

Normas vetoriais devem satisfazer às seguintes propriedades:

1.  $\|\mathbf{x}\| > 0$  se  $\mathbf{x} \neq \mathbf{0}$ ,  $\|\mathbf{x}\| = 0$  se  $\mathbf{x} = \mathbf{0}$
2.  $\|\alpha\mathbf{x}\| = \alpha\|\mathbf{x}\|$ , onde  $\alpha$  é um escalar
3.  $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

## Normas de Vetores e Matrizes

Normas de matrizes tem que satisfazer a propriedades similares:

1.  $\|\mathbf{A}\| > 0$  se  $\mathbf{A} \neq 0$ ,  $\|\mathbf{A}\| = 0$  se  $\mathbf{A} = \mathbf{0}$
2.  $\|\alpha\mathbf{A}\| = \alpha\|\mathbf{A}\|$ , onde  $\alpha$  é um escalar
3.  $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$
4.  $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|$
5.  $\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \|\mathbf{x}\|$

Iremos fazer uso em diversos momentos da seguinte norma matricial

$$\|\mathbf{A}\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

Exemplo

$$\mathbf{A} = \begin{bmatrix} 4 & 6 \\ -3 & 4 \end{bmatrix} \Rightarrow \|\mathbf{A}\|_{\infty} = \max\{10, 7\} = 10$$

## Critério de Parada

A distância entre dois vetores  $\mathbf{x}$  e  $\mathbf{y}$  pode ser calculada como

$$\|\mathbf{x} - \mathbf{y}\|_2 \quad \text{ou} \quad \|\mathbf{x} - \mathbf{y}\|_\infty$$

Iremos usar a norma infinito nos algoritmos que iremos descrever. Seja  $\mathbf{x}^{(k+1)}$  e  $\mathbf{x}^{(k)}$  duas aproximações para o vetor solução  $\mathbf{x}^*$  de um sistema de equações lineares.

Critério de parada

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|_\infty}{\|\mathbf{x}^{(k+1)}\|_\infty} = \frac{\max |x_i^{(k+1)} - x_i^{(k)}|}{\max |x_i^{(k+1)}|} < \varepsilon$$

onde  $\varepsilon$  é a precisão desejada (Ex:  $10^{-3}$ ).

Na prática também adotamos um número máximo de iterações para evitar que o programa execute indefinidamente, caso o método não convirja para um determinado problema.

$$k < k_{max}$$

## Método de Jacobi

Vamos ilustrar a idéia do método de Jacobi através de um exemplo.  
Seja o seguinte sistema:

$$a_{11}x_1 + a_{12}x_2 + a_{13}x_3 = b_1$$

$$a_{21}x_1 + a_{22}x_2 + a_{23}x_3 = b_2$$

$$a_{31}x_1 + a_{32}x_2 + a_{33}x_3 = b_3$$

o qual pode ser escrito como

$$x_1 = (b_1 - a_{12}x_2 - a_{13}x_3)/a_{11}$$

$$x_2 = (b_2 - a_{21}x_1 - a_{23}x_3)/a_{22}$$

$$x_3 = (b_3 - a_{31}x_1 - a_{32}x_2)/a_{33}$$

A partir de uma aproximação inicial

$$\mathbf{x}^{(0)} = \begin{bmatrix} x_1^{(0)} \\ x_2^{(0)} \\ x_3^{(0)} \end{bmatrix}$$

## Método de Jacobi

Calculamos uma nova aproximação  $\mathbf{x}^{(1)}$  através de

$$x_1^{(1)} = \left( b_1 - a_{12}x_2^{(0)} - a_{13}x_3^{(0)} \right) / a_{11}$$

$$x_2^{(1)} = \left( b_2 - a_{21}x_1^{(0)} - a_{23}x_3^{(0)} \right) / a_{22}$$

$$x_3^{(1)} = \left( b_3 - a_{31}x_1^{(0)} - a_{32}x_2^{(0)} \right) / a_{33}$$

Após obter  $\mathbf{x}^{(1)}$ , calculamos  $\mathbf{x}^{(2)}$  substituindo  $\mathbf{x}^{(1)}$  no lugar de  $\mathbf{x}^{(0)}$  na expressão anterior e assim procedemos até que o critério de parada seja satisfeito.

Para um sistema de  $n$  equações e  $n$  incógnitas, a cada passo  $k$ , temos:

**para**  $i = 1 : n$  **faça**

$$\left| \quad x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii} ; \right.$$

**fim-para**



# Método de Jacobi

## Algoritmo

**entrada:**  $\mathbf{A}$ ,  $\mathbf{b}$ ,  $\mathbf{x}^{(0)}$ ,  $max$ ,  $\varepsilon$

**saída:**  $\mathbf{x}$

**para**  $k = 1 : max$  **faça**

**para**  $i = 1 : n$  **faça**

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii} ;$$

**fim-para**

**se**  $\max |x_i^{(k+1)} - x_i^{(k)}| < \varepsilon$  **então**

        retorna  $\mathbf{x}^{(k+1)}$  ;

**fim-se**

**fim-para**

# Método de Jacobi

## Exemplo

Resolver o seguinte sistema:

$$4x_1 + 0.24x_2 - 0.08x_3 = 8$$

$$0.09x_1 + 3x_2 - 0.15x_3 = 9$$

$$0.04x_1 - 0.08x_2 + 4x_3 = 20$$

usando o método de Jacobi com vetor inicial  $\mathbf{x}^{(0)} = \mathbf{0}$ .

## Solução do Exemplo

k	0	1	2	3
$x_1$	0	2	1.92	1.91
$x_2$	0	3	3.19	3.1944
$x_3$	0	5	5.04	5.0446

# Método de Jacobi

## Solução do Exemplo

Fórmula de iteração

$$x_1^{(k+1)} = 2 - 0.06x_2^{(k)} + 0.02x_3^{(k)}$$

$$x_2^{(k+1)} = 3 - 0.03x_1^{(k)} + 0.05x_3^{(k)}$$

$$x_3^{(k+1)} = 5 - 0.01x_1^{(k)} + 0.02x_2^{(k)}$$

Passo 1  $\rightarrow \mathbf{x}^{(0)} = \mathbf{0}$

$$x_1^{(1)} = 2 - 0.06x_2^{(0)} + 0.02x_3^{(0)} = 2$$

$$x_2^{(1)} = 3 - 0.03x_1^{(0)} + 0.05x_3^{(0)} = 3$$

$$x_3^{(1)} = 5 - 0.01x_1^{(0)} + 0.02x_2^{(0)} = 5$$

# Método de Jacobi

## Solução do Exemplo

$$\text{Passo 2} \rightarrow (\mathbf{x}^{(1)})^T = [2 \quad 3 \quad 5]$$

$$x_1^{(2)} = 2 - 0.06(3) + 0.02(5) = 2 - 0.08 = 1.92$$

$$x_2^{(2)} = 3 - 0.03(2) + 0.05(5) = 3 + 0.19 = 3.19$$

$$x_3^{(2)} = 5 - 0.01(2) + 0.02(3) = 5 + 0.04 = 5.04$$

$$\text{Passo 3} \rightarrow (\mathbf{x}^{(2)})^T = [1.92 \quad 3.19 \quad 5.04]$$

$$x_1^{(3)} = 2 - 0.06(3.19) + 0.02(5.04) = 1.91$$

$$x_2^{(3)} = 3 - 0.03(1.92) + 0.05(5.04) = 3.1944$$

$$x_3^{(3)} = 5 - 0.01(1.92) + 0.02(3.19) = 5.0446$$

$$\text{Erro: } \|\mathbf{x}^{(3)} - \mathbf{x}^{(2)}\|_{\infty} = \max\{0.01, 0.0044, 0.0046\} = 0.01$$



## Método de Gauss-Seidel

Observe no exemplo anterior, que o método de Jacobi, não usa os valores atualizados de  $\mathbf{x}^{(k)}$  até completar por inteiro a iteração do passo  $k$ .

O método de Gauss-Seidel pode ser visto como uma modificação do método de Jacobi. Nele usaremos a mesma forma de iterar que o método de Jacobi, entretanto vamos aproveitar os cálculos já atualizados, de outras componentes, para atualizar a componente que está sendo calculada.

Dessa forma o valor de  $x_1^{(k+1)}$  será usado para calcular  $x_2^{(k+1)}$ , os valores de  $x_1^{(k+1)}$  e  $x_2^{(k+1)}$  serão usados para calcular  $x_3^{(k+1)}$ , e assim por diante.

## Método de Gauss-Seidel

Para um sistema  $3 \times 3$  temos o seguinte esquema:

$$x_1^{(k+1)} = \left( b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} \right) / a_{11}$$

$$x_2^{(k+1)} = \left( b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} \right) / a_{22}$$

$$x_3^{(k+1)} = \left( b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} \right) / a_{33}$$

No caso geral temos

**para**  $i = 1 : n$  **faça**

$$\left| \quad x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) / a_{ii} ; \right.$$

**fim-para**

**Obs:** Note que no método de GS apenas 1 aproximação para  $x_i$  precisa ser armazenada. No método de Jacobi é preciso manter 2 vetores em memória, um para  $\mathbf{x}^{(k+1)}$  e outro para  $\mathbf{x}^{(k)}$ .

# Método de Gauss-Seidel

## Exemplo

Resolva o sistema de equações do exemplo anterior usando o método de Gauss-Seidel.

## Solução do Exemplo

Fórmula de iteração (\*)

$$x_1^{(k+1)} = 2 - 0.06x_2^{(k)} + 0.02x_3^{(k)}$$

$$x_2^{(k+1)} = 3 - 0.03x_1^{(k+1)} + 0.05x_3^{(k)}$$

$$x_3^{(k+1)} = 5 - 0.01x_1^{(k+1)} + 0.02x_2^{(k+1)}$$

Passo 1  $\rightarrow \mathbf{x}^{(0)} = \mathbf{0}$

$$x_1^{(1)} = 2 - 0.06(0) + 0.02(0) = 2$$

$$x_2^{(1)} = 3 - 0.03(2) + 0.05(0) = 3 - 0.06 = 2.94$$

$$x_3^{(1)} = 5 - 0.01(2) + 0.02(2.94) = 5.0388$$

# Método de Gauss-Seidel

## Solução do Exemplo

$$\text{Passo 2} \rightarrow (\mathbf{x}^{(1)})^T = [2 \quad 2.94 \quad 5.0388]$$

$$x_1^{(2)} = 2 - 0.06(2.94) + 0.02(5.0388) = 1.924376$$

$$x_2^{(2)} = 3 - 0.03(\mathbf{1.924376}) + 0.05(5.0388) = 3.194209$$

$$x_3^{(2)} = 5 - 0.01(\mathbf{1.924376}) + 0.02(\mathbf{3.194209}) = 5.044640$$

$$\text{Passo 3} \rightarrow (\mathbf{x}^{(2)})^T = [1.924376 \quad 3.194209 \quad 5.044640]$$

$$x_1^{(2)} = 2 - 0.06(1.924376) + 0.02(5.04464) = 1.909240$$

$$x_2^{(2)} = 3 - 0.03(\mathbf{1.909240}) + 0.05(5.04464) = 3.194955$$

$$x_3^{(2)} = 5 - 0.01(\mathbf{1.909240}) + 0.02(\mathbf{3.194955}) = 5.044807$$



## Convergência dos métodos de Jacobi e Gauss-Seidel

Para estudar a convergência dos métodos, vamos primeiros escrevê-los na seguinte forma:

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{c}$$

Para isso, vamos dividir a matriz  $\mathbf{A}$  como

$$\mathbf{A} = \underbrace{\quad}_{\text{triangular inferior}} + \underbrace{\quad}_{\text{diagonal}} + \underbrace{\quad}_{\text{triangular superior}}$$

isto é, para uma matriz  $3 \times 3$  temos

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ a_{21} & 0 & 0 \\ a_{31} & a_{32} & 0 \end{bmatrix} + \begin{bmatrix} a_{11} & 0 & 0 \\ 0 & a_{22} & 0 \\ 0 & 0 & a_{33} \end{bmatrix} + \begin{bmatrix} 0 & a_{12} & a_{13} \\ 0 & 0 & a_{23} \\ 0 & 0 & 0 \end{bmatrix}$$

## Convergência dos métodos de Jacobi e Gauss-Seidel

Sendo assim o método de Jacobi pode ser escrito como:

$$\begin{aligned}\mathbf{Ax} = \mathbf{b} &\Rightarrow (\mathbf{L} + \mathbf{D} + \mathbf{U})\mathbf{x} = \mathbf{b} \\ &\Rightarrow \mathbf{D}\mathbf{x} = \mathbf{b} - (\mathbf{L} + \mathbf{U})\mathbf{x}\end{aligned}$$

e assim

$$\begin{aligned}\mathbf{D}\mathbf{x}^{(k+1)} &= \mathbf{b} - (\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} \\ \mathbf{x}^{(k+1)} &= -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b} \\ \mathbf{x}^{(k+1)} &= \mathbf{B}_J\mathbf{x}^{(k)} + \mathbf{c}\end{aligned}$$

onde para o método de Jacobi

$$\begin{aligned}\mathbf{B}_J &= -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) \\ \mathbf{c} &= \mathbf{D}^{-1}\mathbf{b}\end{aligned}$$

## Convergência dos métodos de Jacobi e Gauss-Seidel

Para o método de Gauss-Seidel temos

$$(\mathbf{L} + \mathbf{D})\mathbf{x}^{(k+1)} = -\mathbf{U}\mathbf{x}^{(k)} + \mathbf{b}$$

$$\mathbf{x}^{(k+1)} = -(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}\mathbf{x}^{(k)} + (\mathbf{L} + \mathbf{D})^{-1}\mathbf{b}$$

$$\mathbf{x}^{(k+1)} = \mathbf{B}_{GS}\mathbf{x}^{(k)} + \mathbf{c}$$

onde para o método de Gauss-Seidel

$$\mathbf{B}_{GS} = -(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}$$

$$\mathbf{c} = (\mathbf{L} + \mathbf{D})^{-1}\mathbf{b}$$

Ou seja, ambos os métodos podem ser escritos como

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{c} \tag{9}$$

onde  $\mathbf{B}$  é chamada de matriz de iteração

$$\mathbf{B}_J = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})$$

$$\mathbf{B}_{GS} = -(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}$$

## Convergência dos métodos de Jacobi e Gauss-Seidel

Se o método de Jacobi ou Gauss-Seidel converge ou não, depende dos autovalores da matriz de iteração  $\mathbf{B}$ .

Dizemos que  $\lambda_i$ ,  $i = 1 : n$  é um autovalor da matriz  $\mathbf{B}$  se

$$\mathbf{B}\mathbf{u} = \lambda_i\mathbf{u}$$

para algum vetor  $\mathbf{u} \neq \mathbf{0}$ . O seguinte teorema caracteriza a condição para convergência desses métodos.

### Teorema

*A condição necessária e suficiente para que o método iterativo descrito por  $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{c}$  convirja usando um vetor inicial  $\mathbf{x}^{(0)}$  qualquer é*

$$\rho(\mathbf{B}) = \max_{1 \leq i \leq n} |\lambda_i(\mathbf{B})| < 1$$

## Convergência dos métodos de Jacobi e Gauss-Seidel

Na prática encontrar os autovalores de  $\mathbf{B}$  é tão custoso quanto resolver um sistema de equações lineares e portanto o Teorema 1 é difícil de usar. Vamos estudar outra forma de analisar a convergência para esses métodos.

Seja  $\mathbf{x}^*$  a solução exata. Então  $\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{c}$ . Subtraindo de (9) temos

$$\begin{aligned}\mathbf{x}^{(k+1)} - \mathbf{x}^* &= \mathbf{B}\mathbf{x}^{(k)} - \mathbf{B}\mathbf{x}^* + \mathbf{c} - \mathbf{c} \\ &= \mathbf{B}(\mathbf{x}^{(k)} - \mathbf{x}^*)\end{aligned}$$

de forma análoga

$$\mathbf{x}^{(k)} - \mathbf{x}^* = \mathbf{B}(\mathbf{x}^{(k-1)} - \mathbf{x}^*)$$

e assim

$$\mathbf{x}^{(k+1)} - \mathbf{x}^* = \mathbf{B}^2(\mathbf{x}^{(k-1)} - \mathbf{x}^*) = \dots = \mathbf{B}^{k+1}(\mathbf{x}^{(0)} - \mathbf{x}^*)$$

## Convergência dos métodos de Jacobi e Gauss-Seidel

$$\mathbf{x}^{(k+1)} - \mathbf{x}^* = \mathbf{B}^{k+1}(\mathbf{x}^{(0)} - \mathbf{x}^*) \quad (10)$$

Aplicando a norma infinito em (10), obtemos

$$\begin{aligned} \|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|_\infty &= \|\mathbf{B}^{k+1}(\mathbf{x}^{(0)} - \mathbf{x}^*)\|_\infty \\ &\leq \|\mathbf{B}^{k+1}\|_\infty \|(\mathbf{x}^{(0)} - \mathbf{x}^*)\|_\infty \\ &\leq \|\mathbf{B}\|_\infty^{k+1} \|(\mathbf{x}^{(0)} - \mathbf{x}^*)\|_\infty \end{aligned} \quad (11)$$

Assim de (11) fica claro que só haverá convergência se

$$\|\mathbf{B}\|_\infty < 1 \quad (12)$$

Vamos analisar agora critérios específicos para atender ao critério geral dado por (12) para o método de Jacobi e Gauss-Seidel.

# Convergência dos métodos de Jacobi e Gauss-Seidel

Para o método de Jacobi, a matriz de iteração

$\mathbf{B}_J = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})$  é da forma

$$\mathbf{D} = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \Rightarrow \mathbf{D}^{-1} = \begin{bmatrix} \frac{1}{a_{11}} & & & \\ & \frac{1}{a_{22}} & & \\ & & \ddots & \\ & & & \frac{1}{a_{nn}} \end{bmatrix}$$

portanto

$$\mathbf{B}_J = - \begin{bmatrix} 0 & \frac{a_{12}}{a_{11}} & \frac{a_{13}}{a_{11}} & \dots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 0 & \frac{a_{23}}{a_{22}} & \dots & \frac{a_{2n}}{a_{22}} \\ \vdots & & \ddots & & \vdots \\ \frac{a_{n1}}{a_{nn}} & \frac{a_{n2}}{a_{nn}} & \dots & \frac{a_{nn-1}}{a_{nn}} & 0 \end{bmatrix}$$

ou seja, seus elementos são

$$b_{ij} = -\frac{a_{ij}}{a_{ii}}$$

## Convergência dos métodos de Jacobi e Gauss-Seidel

Para termos convergência, então precisamos que  $\|\mathbf{B}_J\|_\infty < 1$

$$\|\mathbf{B}_J\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |b_{ij}| = \max_{1 \leq i \leq n} \sum_{j=1, i \neq j}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1$$

### Teorema (Critério das Linhas)

Seja  $\mathbf{Ax} = \mathbf{b}$  e seja  $\alpha_k = \sum_{j=1, i \neq j}^n \left| \frac{a_{ij}}{a_{ii}} \right|$ , para  $k = 1 : n$ . Se

$\alpha = \max\{\alpha_k\} < 1$ , então o método de Jacobi converge independentemente da aproximação inicial  $\mathbf{x}^{(0)}$ .

### Exemplo

Verificar se as seguintes matrizes satisfazem o critério das linhas.

$$\begin{bmatrix} 4 & 0.24 & -0.08 \\ 0.09 & 3 & -0.15 \\ 0.04 & -0.08 & 4 \end{bmatrix}, \quad \begin{bmatrix} 1 & 3 & 1 \\ 5 & 2 & 2 \\ 0 & 6 & 8 \end{bmatrix}$$



# Convergência dos métodos de Jacobi e Gauss-Seidel

## Definição

*Uma matriz  $\mathbf{A}$  é estritamente diagonal dominante se*

$$\sum_{j=1, j \neq i}^n |a_{ij}| < |a_{ii}|, \quad i = 1 : n$$

Fica claro então que para matrizes estritamente diagonal dominante o critério das linhas é sempre satisfeito. Portanto, uma outra forma de verificar se o método de Jacobi converge para uma certa matriz é verificar se esta é estritamente diagonal dominante.

## Exemplo

$$\begin{bmatrix} 10 & 2 & 1 \\ 1 & 5 & 1 \\ 2 & 3 & 10 \end{bmatrix}$$

$$|a_{12}| + |a_{13}| = |2| + |1| < |10| = |a_{11}|$$

$$|a_{21}| + |a_{23}| = |1| + |1| < |5| = |a_{22}|$$

$$|a_{31}| + |a_{32}| = |2| + |3| < |10| = |a_{33}|$$

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Gauss-Seidel

Para ter convergência é preciso satisfazer pelo menos um dos critérios:

- ▶ critério das linhas, isto é

$$\max_{1 \leq i \leq n} \sum_{j=1, j \neq i}^n \frac{|a_{ij}|}{|a_{ii}|} < 1$$

- ▶ critério de Sassenfeld

$$\max_{1 \leq i \leq n} \beta_i < 1 \quad (13)$$

onde  $\beta_i$  são calculados como

$$\beta_i = \left( \sum_{j=1}^{i-1} |a_{ij}| \beta_j + \sum_{j=i+1}^n |a_{ij}| \right) / |a_{ii}|$$

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Gauss-Seidel

É possível mostrar que para  $\mathbf{B}_{GS}$  dado por

$$\mathbf{B}_{GS} = -(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}$$

temos que

$$\|\mathbf{B}_{GS}\|_{\infty} \leq \max_{1 \leq i \leq n} \beta_i$$

Sendo assim, para mostrar que o método converge, basta mostrar que o critério de Sassenfeld (13) é satisfeito.

\* Para ver que o critério das linhas também é válido para o método de Gauss-Seidel, basta verificar que

$$\max_{1 \leq i \leq n} \sum_{j=1, j \neq i}^n \frac{|a_{ij}|}{|a_{ii}|} < 1 \quad \Rightarrow \quad \beta_i < 1, \quad i = 1 : n$$

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Gauss-Seidel

Prova: Considere que:  $\max \sum_{j=1, j \neq i}^n \frac{|a_{ij}|}{|a_{ii}|} < 1$  (CL  $\rightarrow$  OK)

$$\beta_1 = \sum_{j=2}^n \frac{|a_{1j}|}{|a_{11}|} \leq \max_{1 \leq i \leq n} \sum_{j=1, j \neq i}^n \frac{|a_{ij}|}{|a_{ii}|} < 1$$

Suponha agora que  $\beta_j < 1$  para  $i = 1, 2, \dots, i-1$ . Então

$$\begin{aligned} \beta_i &= \sum_{j=1}^{i-1} \frac{|a_{ij}|}{|a_{ii}|} \beta_j + \sum_{j=i+1}^n \frac{|a_{ij}|}{|a_{ii}|} \leq \sum_{j=1, j \neq i}^n \frac{|a_{ij}|}{|a_{ii}|} \\ &\leq \max_{1 \leq i \leq n} \sum_{j=1, j \neq i}^n \frac{|a_{ij}|}{|a_{ii}|} < 1 \end{aligned}$$

Fica claro que o critério de Sassenfeld pode ser menor que o das linhas. Logo, o critério de Sassenfeld pode ser satisfeito e o critério das linhas não, e portanto o processo iterativo converge.

# Convergência dos métodos de Jacobi e Gauss-Seidel

Algumas observações:

- ▶ Para um certo sistema de equações lineares pode acontecer do método de Jacobi convergir, enquanto o Gauss-Seidel não, ou vice-versa.
- ▶ Quanto menor o valor de  $\|\mathbf{B}\|_\infty$ , mais rápida será a convergência do método.
- ▶ Permutação de linhas ou colunas pode reduzir  $\|\mathbf{B}\|_\infty$
- ▶ A convergência dos métodos de Jacobi e Gauss-Seidel não depende do vetor inicial  $\mathbf{x}^{(0)}$ .

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Exemplo

Resolva o sistema utilizando o método de Jacobi.

$$\begin{bmatrix} 10 & 2 & 1 \\ 1 & 5 & 1 \\ 2 & 3 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 7 \\ -8 \\ 6 \end{bmatrix}$$

## Solução do Exemplo

Critério das linhas:

$$\alpha_1 = (|a_{12}| + |a_{13}|)/|10| = 0.2 + 0.1 = 0.3 < 1$$

$$\alpha_2 = (|a_{21}| + |a_{23}|)/|5| = 0.2 + 0.2 = 0.4 < 1$$

$$\alpha_3 = (|a_{31}| + |a_{32}|)/|10| = 0.2 + 0.3 = 0.5 < 1$$

Logo  $\alpha = \alpha_3 = 0.5 < 1$  e portanto o método de Jacobi converge para essa matriz.

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Solução do Exemplo

Ou então basta verificar que a matriz  $\mathbf{A}$  é estritamente diagonal dominante.

Fórmula de iteração:

$$x_1^{(k+1)} = 0.7 - 0.2x_2^{(k)} - 0.1x_3^{(k)}$$

$$x_2^{(k+1)} = -1.6 - 0.2x_1^{(k)} - 0.2x_3^{(k)}$$

$$x_3^{(k+1)} = 0.6 - 0.2x_1^{(k)} - 0.3x_2^{(k)}$$

Assim temos as seguintes iterações para o vetor inicial  $\mathbf{x}^{(0)} = \mathbf{0}$

k	1	2	3	4	5
$x_1$	0.7	0.96	0.978	0.9994	0.9979
$x_2$	-1.6	-1.86	-1.98	-1.9888	-1.9996
$x_3$	0.6	0.94	0.966	0.966	0.9968

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Exemplo

Resolva o sistema utilizando o método de Gauss-Seidel.

$$\begin{bmatrix} 5 & 1 & 1 \\ 3 & 4 & 1 \\ 3 & 3 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 5 \\ 6 \\ 0 \end{bmatrix}$$

## Solução do Exemplo

1) A matriz não é estritamente diagonal dominante. Nada podemos afirmar sobre a convergência.

2) Critério das linhas:

$$\alpha_1 = (|a_{12}| + |a_{13}|)/|5| = 0.2 + 0.2 = 0.4 < 1$$

$$\alpha_2 = (|a_{21}| + |a_{23}|)/|4| = 0.75 + 0.25 = 1$$

$$\alpha_3 = (|a_{31}| + |a_{32}|)/|6| = 0.5 + 0.5 = 1$$

Não satisfaz o critério das linhas.



# Convergência dos métodos de Jacobi e Gauss-Seidel

## Solução do Exemplo

3) Critério de Sassenfeld:

$$\beta_1 = |0.2| + |0.2| = 0.4$$

$$\beta_2 = |0.75|(0.4) + |0.25| = 0.3 + 0.25 = 0.55$$

$$\beta_3 = |0.5|(0.4) + |0.5|(0.55) = 0.2 + 0.275 = 0.475$$

Assim

$$\max_{1 \leq i \leq n} \beta_i = \max\{0.4, 0.55, 0.475\} = 0.55 < 1$$

Portanto, como o critério de Sassenfeld é satisfeito, podemos garantir que o processo de Gauss-Seidel converge para essa matriz.

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Solução do Exemplo

Fórmula de iteração:

$$x_1^{(k+1)} = 1 - 0.2x_2^{(k)} - 0.2x_3^{(k)}$$

$$x_2^{(k+1)} = 1.5 - 0.75x_1^{(k+1)} - 0.25x_3^{(k)}$$

$$x_3^{(k+1)} = 0 - 0.5x_1^{(k+1)} - 0.5x_2^{(k+1)}$$

Usando  $\mathbf{x}^{(0)} = \mathbf{0}$  como aproximação inicial, temos

$$x_1^{(1)} = 1 - 0.2(0) - 0.2(0) = 1$$

$$x_2^{(1)} = 1.5 - 0.75(1) - 0.25(0) = 0.75$$

$$x_3^{(1)} = 0 - 0.5(1) - 0.5(0.75)$$

# Convergência dos métodos de Jacobi e Gauss-Seidel

## Solução do Exemplo

Iterando para  $k = 1, 2, \dots$  temos

k	1	2	3	4
$x_1$	1.0	1.025	1.0075	1.0016
$x_2$	0.75	0.95	0.9913	0.9987
$x_3$	-0.875	-0.9875	-0.9994	-1.0002

Podemos verificar o erro

$$\begin{aligned}\frac{\|\mathbf{x}^{(4)} - \mathbf{x}^{(3)}\|_{\infty}}{\|\mathbf{x}^{(4)}\|_{\infty}} &= \frac{\max\{|1.0016 - 1.0075|, |0.9987 - 0.9913|, |-1.0002 + 0.9994|\}}{\max\{|1.0016|, |0.9987|, |-1.0002|\}} \\ &= \frac{0.0074}{1.0016} = 0.0074 < 10^{-2}\end{aligned}$$



## Método SOR

É possível acelerar a convergência dos métodos iterativos visto até então através do método da sobre-relaxação sucessiva, ou do inglês SOR (*sucessive over relaxation*).

Nesse método definimos a aproximação na iteração  $(k + 1)$  como uma média entre o valor de  $\mathbf{x}^{(k)}$  obtido na iteração  $(k)$  e o valor de  $\mathbf{x}^{(k+1)}$ , que seria obtido pelo método de Gauss-Seidel.

As iterações associadas ao parâmetro  $\omega$  do método SOR são definidas por:

$$\mathbf{x}_{\text{SOR}}^{(k+1)} = (1 - \omega)\mathbf{x}_{\text{SOR}}^{(k)} + \omega\mathbf{x}_{\text{GS}}^{(k+1)} \quad (14)$$

onde  $\mathbf{x}_{\text{SOR}}^{(k)}$  é a aproximação do passo anterior obtida pelo método SOR e  $\mathbf{x}_{\text{GS}}^{(k+1)}$  é a aproximação atual obtida pelo método de Gauss-Seidel.

# Método SOR

Lembrando que para o método de Gauss-Seidel temos

$$x_i^{(k+1)} = \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) / a_{ii}$$

chegamos ao seguinte esquema para o método SOR:

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

- ▶ Quando  $\omega = 1$  temos o método de Gauss-Seidel.
- ▶ O método só converge se  $0 < \omega < 2$ .
- ▶  $1 < \omega < 2$ : sobre-relaxação.
- ▶  $0 < \omega < 1$ : sub-relaxação.
- ▶ Em alguns casos particulares é possível encontrar um valor ótimo para  $\omega$ , de forma que o método apresenta uma boa convergência com relação a outras escolhas de  $\omega$