

DCC008 - Cálculo Numérico

Método dos Mínimos Quadrados

Bernardo Martins Rocha

Departamento de Ciência da Computação
Universidade Federal de Juiz de Fora
`bernardomartinsrocha@ice.ufjf.br`

Conteúdo

- ▶ Introdução
- ▶ Caso discreto
 - ▶ Regressão linear
 - ▶ Caso geral
 - ▶ Caso não-linear
- ▶ Caso contínuo
- ▶ Polinômio ortogonais

Introdução

Existem duas classes de métodos para a aproximação de dados, e a distinção entre elas está em considerarmos, ou não, a existência de erro nos dados.

No primeiro caso, consideramos que não existem erros nos dados e podemos exigir que a curva passe pelos pontos dados. Como vimos, esse problema é resolvido com **interpolação**.

Nesse caso aproximamos uma função $f(x)$ por uma função polinomial $p(x)$ que passa exatamente pelos pontos dados $(x_0, y_0), \dots, (x_n, y_n)$. Assim dado $p(x)$ é possível estimar o valor de $f(\bar{x})$ para um ponto \bar{x} diferente dos pontos x_i , para $i = 0, 1, \dots, n$.

A outra classe de métodos leva em consideração possíveis erros introduzidos na obtenção dos dados (limitações do instrumento, condições experimentais, etc).

Introdução


No segundo caso o **método dos mínimos quadrados** tem sido amplamente utilizado.

Para ilustrar a idéia, considere agora o problema de determinar a constante de uma mola. A Lei de Hooke nos diz que o deslocamento de uma mola é proporcional à força nela aplicada. A questão é como encontrar essa constante de proporcionalidade a partir de dados experimentais.

$$\text{Lei de Hooke} \quad \Rightarrow \quad F = kx$$

Suponha que possamos realizar vários experimentos medindo forças aplicadas à mola e os seus respectivos deslocamentos.


Introdução



O problema consiste em encontrar uma reta que melhor aproxime esses dados. A inclinação da reta irá nos fornecer a constante k da mola.

Introdução

Outro exemplo: $f(x) = ae^{bx}$



O método dos mínimos quadrados é uma das técnicas mais usadas em problemas práticos porque em geral buscamos aproximações para dados que são medidas obtidas experimentalmente e possuem um certo grau de incerteza.

Introdução

Interpolação e Mínimos Quadrados




Figura: Interpolação




Figura: Mínimos Quadrados

Método dos mínimos quadrados

Vamos chamar de $f(x)$ a função que queremos aproximar por uma outra função $g(x)$.

Nem sempre temos uma expressão analítica para $f(x)$.

No método dos mínimos quadrados (MMQ) partimos da hipótese de que temos algumas informações sobre a forma de $g(x)$.

Poderíamos saber, através da observação dos dados, por exemplo, que $g(x)$ é uma reta,

$$g(x) = c_0 + c_1x$$

ou que é uma parábola

$$g(x) = c_0 + c_1x + c_2x^2$$

ou que tenha alguma outra forma específica.

Método dos mínimos quadrados

De forma geral, no **caso linear**, vamos considerar que a aproximação será por uma função do tipo:

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x) \quad (1)$$

onde $\phi_0(x), \phi_1(x), \dots, \phi_n(x)$ são **funções pré-estabelecidas**.

MMQ linear: a função $g(x)$ que aproxima $f(x)$ é linear nos seus parâmetros c_0, c_1, \dots, c_n .

Exemplos:

$$\phi_0(x) = 1, \quad \phi_1(x) = x, \quad \phi_2(x) = x^2, \quad \dots$$

$$\phi_0(x) = \sin(\pi x), \quad \phi_1(x) = \sin(2\pi x), \quad \dots$$

Veremos mais adiante como trabalhar no **caso não-linear**, como por exemplo quando $g(x) = c_0 e^{c_1 x}$.

Método dos mínimos quadrados

Para cada conjunto de coeficientes c_i , $i = 0, 1, \dots, n$, o desvio ou resíduo da aproximação dada pela eq. (1) no ponto x_k é dado por

$$\begin{aligned} r(x_k) &= f(x_k) - g(x_k) \\ &= f(x_k) - [c_0\phi_0(x_k) + c_1\phi_1(x_k) + \dots + c_n\phi_n(x_k)] \\ &= r(x_k; c_0, c_1, \dots, c_n) \end{aligned}$$

Precisamos de estabelecer critérios de aproximação para encaminhar o problema da determinação dos parâmetros c_0, \dots, c_n que nos levarão à *"melhor aproximação"*.


Vamos ver um exemplo para começar a discussão.

Método dos mínimos quadrados

Suponha que temos a seguinte tabela de dados

x_i	0.3	2.7	4.5	5.9	7.8
y_i	1.8	1.9	3.1	3.9	3.3



Vamos analisar os dados.



Método dos mínimos quadrados

Podemos considerar que existe uma relação aproximadamente linear entre as variáveis. Logo, podemos desprezar alguns pontos da tabela, escolher 2 pontos e usar polinômios interpoladores lineares para aproximação. Ou seja $g(x) = c_0 + c_1x$.

- ▶ Para (0.3, 1.8) e (7.8, 3.3) temos $g_1(x) = 1.74 + 0.2x$.
- ▶ Para (2.7, 1.9) e (5.9, 3.9) temos $g_2(x) = 0.2125 + 0.625x$.




Qual aproximação é melhor? $g_1(x)$ ou $g_2(x)$?

Como verificar a qualidade da aproximação?

Método dos mínimos quadrados

Para obter as aproximações g_1 e g_2 desprezamos vários dados da tabela para fazer a interpolação, o que não é muito conveniente de se fazer.

Um modo de se verificar a qualidade da aproximação é calculando a soma de todas as distâncias verticais de $f(x_i)$ e $g(x_i)$ ao quadrado, isto é



$$\begin{aligned} E^2 &= \sum_{i=1}^m r(x_i)^2 = \sum_{i=1}^m [f(x_i) - g(x_i)]^2 \\ &= \sum_{i=1}^m [f(x_i) - c_0 - c_1 x_i]^2 \end{aligned}$$

Método dos mínimos quadrados

Para $g_1(x) = 1.74 + 0.2x$

i	x_i	$f(x_i)$	$g(x_i)$	r_i^2
1	0.3	1.8	1.8	0
2	2.7	1.9	2.28	0.144
3	4.5	3.1	2.64	0.2116
4	5.9	3.9	2.92	0.9604
5	7.8	3.3	3.3	0

Para $g_2(x) = 0.2125 + 0.625x$

i	x_i	$f(x_i)$	$g(x_i)$	r_i^2
1	0.3	1.8	0.4	1.96
2	2.7	1.9	1.9	0
3	4.5	3.1	3.025	0.0056
4	5.9	3.9	3.9	0
5	7.8	3.3	5.0875	3.1952

$$E^2 = 1.316$$

$$E^2 = 3.0166$$

Logo, $g_1(x)$ é mais adequado de acordo com esse critério de erros ao quadrado.

Como escolher c_0 e c_1 de forma que E^2 seja mínimo?

Método dos mínimos quadrados

Até então falamos em aproximação de dados discretos, isto é, aproximar $f(x)$ sabendo os valores de f em um conj. de pontos x_i .

Podemos trabalhar com o caso de aproximar $f(x)$, uma função conhecida para todo x , por uma função mais simples como $g(x)$. No **caso contínuo** do método dos mínimos quadrados temos que minimizar

$$\int_a^b r(x)^2 dx = \int_a^b (f(x) - g(x))^2 dx$$

Vamos introduzir formalmente a definição de produto escalar entre funções para que possamos medir o resíduo:

$$\langle f, g \rangle = \begin{cases} \sum_{i=1}^m f(x_i)g(x_i), & \text{caso discreto} \\ \int_a^b f(x)g(x) dx, & \text{caso contínuo} \end{cases}$$

Método dos mínimos quadrados

O método dos mínimos quadrados consiste na procura de parâmetros (c_0, c_1, \dots, c_n) que minimizem:

- ▶ a soma dos quadrados dos resíduos (caso discreto), ou,
- ▶ a integral da função resíduo ao quadrado (caso contínuo).

Desta forma, introduzindo a notação do produto escalar temos

$$\langle r, r \rangle = \sum_{i=1}^m [r(x_i)]^2 = \sum_{i=1}^m [f(x_i) - g(x_i)]^2$$

Como vimos $\langle r, r \rangle$ é função dos parâmetros c_0, c_1, \dots, c_n , isto é, $\langle r, r \rangle = \langle r, r \rangle (c_0, c_1, \dots, c_n)$.

Antes de estudar o método de forma geral no caso discreto, vamos ver um exemplo simples: **regressão linear**.

Método dos mínimos quadrados

Regressão linear

Dada uma tabela de dados $(x_i, f(x_i))$, $i = 1, \dots, m$, queremos encontrar a reta que melhor se ajusta aos dados no critério dos mínimos quadrados. Como o ajuste será feito por uma reta temos que $\phi_0(x) = 1$ e $\phi_2(x) = x$, ou seja

$$f(x) \approx g(x) = c_0 + c_1x$$

o resíduo é dado por

$$r = f(x) - c_0 - c_1x$$

Pelo método dos mínimos quadrados devemos encontrar c_0 e c_1 que **minimizem** a função

$$\langle r, r \rangle = \langle f(x) - c_0 - c_1x, f(x) - c_0 - c_1x \rangle \quad (2)$$

$$= \sum_{i=1}^m [f(x_i) - c_0 - c_1x_i]^2 \quad (3)$$

Método dos mínimos quadrados

Regressão linear

Do Cálculo sabemos que a condição necessária de ponto crítico é que as derivadas nele sejam nulas, isto é

$$\frac{\partial}{\partial c_0} < r, r > = 0, \quad \frac{\partial}{\partial c_1} < r, r > = 0$$

Derivando a Eq. (2) com relação a c_0 temos

$$\begin{aligned} \frac{\partial}{\partial c_0} < r, r > &= \frac{\partial}{\partial c_0} \left\{ \sum_{i=1}^m [f(x_i) - c_0 - c_1 x_i]^2 \right\} \\ &= -2 \sum_{i=1}^m [f(x_i) - c_0 - c_1 x_i] \end{aligned}$$

Método dos mínimos quadrados

Regressão linear

De forma similar, derivando a Eq. (3) com relação a c_1 temos

$$\begin{aligned}\frac{\partial}{\partial c_1} \langle r, r \rangle &= \frac{\partial}{\partial c_1} \left\{ \sum_{i=1}^m [f(x_i) - c_0 - c_1 x_i]^2 \right\} \\ &= -2 \sum_{i=1}^m [f(x_i) - c_0 - c_1 x_i] (x_i)\end{aligned}$$

Condição de ponto crítico:

$$\begin{aligned}\frac{\partial}{\partial c_0} \langle r, r \rangle = 0 &\Rightarrow \sum_{i=1}^m [f(x_i) - c_0 - c_1 x_i] = 0 \\ \frac{\partial}{\partial c_1} \langle r, r \rangle = 0 &\Rightarrow \sum_{i=1}^m (x_i) [f(x_i) - c_0 - c_1 x_i] = 0\end{aligned}$$

Método dos mínimos quadrados

Regressão linear

Manipulando as expressões temos

$$\sum_{i=1}^m f(x_i) = \sum_{i=1}^m c_0 + c_1 x_i = c_0 m + c_1 \sum_{i=1}^m x_i$$

$$\sum_{i=1}^m x_i f(x_i) = \sum_{i=1}^m x_i (c_0 + c_1 x_i) = c_0 \sum_{i=1}^m x_i + c_1 \sum_{i=1}^m x_i^2$$

chegamos a

$$\begin{aligned} c_0 m + c_1 \sum_{i=1}^m x_i &= \sum_{i=1}^m f(x_i) \\ c_0 \sum_{i=1}^m x_i + c_1 \sum_{i=1}^m x_i^2 &= \sum_{i=1}^m x_i f(x_i) \end{aligned}$$

Método dos mínimos quadrados

Regressão linear

$$\begin{aligned}c_0 m + c_1 \sum_{i=1}^m x_i &= \sum_{i=1}^m f(x_i) \\ c_0 \sum_{i=1}^m x_i + c_1 \sum_{i=1}^m x_i^2 &= \sum_{i=1}^m x_i f(x_i)\end{aligned}$$

pode ser escrito na forma:

$$\begin{bmatrix} m & \sum_{i=1}^m x_i \\ \sum_{i=1}^m x_i & \sum_{i=1}^m x_i^2 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^m f(x_i) \\ \sum_{i=1}^m x_i f(x_i) \end{bmatrix} \quad (4)$$

Temos que, resolvendo o sistema de equações lineares encontramos c_0 e c_1 , e assim determinamos $g(x) = c_0 + c_1 x$.

Método dos mínimos quadrados

Regressão linear

Vejamos um exemplo numérico para ilustrar o procedimento.
Considere a seguinte tabela de dados:

x_i	0	0.25	0.5	0.75	1
$f(x_i)$	1	1.2840	1.6487	2.1170	2.7183

Precisamos montar o sistema de equações lineares dado por (4) para encontrar c_0 e c_1 e assim determinar $g(x)$.

$$\begin{aligned}\sum_{i=1}^5 x_i &= 2.5 & \sum_{i=1}^5 x_i^2 &= 1.875 \\ \sum_{i=1}^5 f(x_i) &= 8.768 & \sum_{i=1}^5 x_i f(x_i) &= 5.4514\end{aligned}$$

Método dos mínimos quadrados

Regressão linear

Logo temos o seguinte sistema


$$5c_0 + 2.5c_1 = 8.768$$

$$2.5c_0 + 1.875c_1 = 5.4514$$

Resolvendo encontramos

$$c_0 = 0.89968$$

$$c_1 = 1.70784 \quad \Rightarrow \quad g(x) = 0.89968 + 1.70784x$$



Método dos mínimos quadrados

Caso Geral

De forma geral, queremos aproximar $f(x)$ por

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

onde $\phi_j(x)$ são funções conhecidas. Assim para encontrar os parâmetros c_0, c_1, \dots, c_n é preciso minimizar a função:

$$\begin{aligned} \langle r, r \rangle &= \langle f - c_0\phi_0 - \dots - c_n\phi_n, f - c_0\phi_0 - \dots - c_n\phi_n \rangle \\ &= \sum_{i=1}^m \left[f(x_i) - \sum_{j=0}^n c_j\phi_j(x_i) \right]^2 \end{aligned}$$

Derivando com relação a cada um dos parâmetros c_k e igualando a zero temos

$$\frac{\partial}{\partial c_k} \langle r, r \rangle = -2 \sum_{i=1}^m \left[f(x_i) - \sum_{j=0}^n c_j\phi_j(x_i) \right] \phi_k(x_i) = 0$$

Método dos mínimos quadrados

Caso Geral

$$\begin{aligned} & -2 \sum_{i=1}^m \left[f(x_i) - \sum_{j=0}^n c_j \phi_j(x_i) \right] \phi_k(x_i) = 0 \\ \Rightarrow & \sum_{i=1}^m \left\{ \left[f(x_i) - \sum_{j=0}^n c_j \phi_j(x_i) \right] \phi_k(x_i) \right\} = 0 \\ \Rightarrow & \sum_{i=1}^m \left[\sum_{j=0}^n c_j \phi_j(x_i) \phi_k(x_i) \right] = \sum_{i=1}^m f(x_i) \phi_k(x_i) \\ \Rightarrow & \sum_{j=0}^n c_j \left(\sum_{i=1}^m \phi_j(x_i) \phi_k(x_i) \right) = \sum_{i=1}^m f(x_i) \phi_k(x_i) \end{aligned}$$

Lembrando que

$$\langle f, g \rangle = \sum_{i=1}^m f(x_i) g(x_i)$$

Método dos mínimos quadrados

Caso Geral

Usando a notação de produto escalar podemos escrever

$$\Rightarrow \sum_{j=0}^n c_j \underbrace{\left(\sum_{i=1}^m \phi_j(x_i) \phi_k(x_i) \right)}_{\langle \phi_j, \phi_k \rangle = \langle \phi_k, \phi_j \rangle} = \underbrace{\sum_{i=1}^m f(x_i) \phi_k(x_i)}_{\langle f, \phi_k \rangle = \langle \phi_k, f \rangle}$$

$$\Rightarrow \boxed{\sum_{j=0}^n c_j \langle \phi_k, \phi_j \rangle = \langle f, \phi_k \rangle}, \quad \text{para } k = 0, 1, \dots, n$$

que é um sistema de equações lineares $(n+1) \times (n+1)$.

Exemplo para $n = 2$:

$$\begin{aligned} \langle \phi_0, \phi_0 \rangle c_0 + \langle \phi_0, \phi_1 \rangle c_1 + \langle \phi_0, \phi_2 \rangle c_2 &= \langle \phi_0, f \rangle \\ \langle \phi_1, \phi_0 \rangle c_0 + \langle \phi_1, \phi_1 \rangle c_1 + \langle \phi_1, \phi_2 \rangle c_2 &= \langle \phi_1, f \rangle \\ \langle \phi_2, \phi_0 \rangle c_0 + \langle \phi_2, \phi_1 \rangle c_1 + \langle \phi_2, \phi_2 \rangle c_2 &= \langle \phi_2, f \rangle \end{aligned}$$

Método dos mínimos quadrados

Caso Geral

Escrevendo de forma matricial temos

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle & \langle \phi_0, \phi_2 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle & \langle \phi_1, \phi_2 \rangle \\ \langle \phi_2, \phi_0 \rangle & \langle \phi_2, \phi_1 \rangle & \langle \phi_2, \phi_2 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \langle \phi_0, f \rangle \\ \langle \phi_1, f \rangle \\ \langle \phi_2, f \rangle \end{bmatrix}$$

De forma geral o sistema é dado por

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle & \dots & \langle \phi_0, \phi_n \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle & \dots & \langle \phi_1, \phi_n \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \phi_n, \phi_0 \rangle & \langle \phi_n, \phi_1 \rangle & \dots & \langle \phi_n, \phi_n \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{bmatrix} = \begin{bmatrix} \langle \phi_0, f \rangle \\ \langle \phi_1, f \rangle \\ \vdots \\ \langle \phi_n, f \rangle \end{bmatrix}$$

o qual é chamado de **sistema normal** ou **equações normais**.


Observe que a matriz é simétrica, pois $\langle f, g \rangle = \langle g, f \rangle$.

Método dos mínimos quadrados

[Home](#) > [Linear Least Squares](#) >

Least Squares Data Fitting

This module demonstrates fitting a polynomial to a set of data points using the method of least squares. For a given number of data points, a polynomial of relatively low degree tends to capture the general trend of the data, glossing over minor deviations, whereas a polynomial of higher degree follows the data more closely but with a more oscillatory curve. With a polynomial of sufficiently high degree (one less than the number of data points), the data can be fit exactly, but this is often undesirable if the data are noisy.



Select points by clicking on the graph, or press: [Example](#)

Degree of polynomial: ▼

☒ Fit Y to X

☐ Fit X to Y

[Refresh](#)

[View Polynomial](#)

[Reset](#)

Método dos mínimos quadrados

Exemplo

Dada a seguinte tabela

x	-1	0	1	2
y	0	-1	0	7

aproximar $f(x)$ por um polinômio quadrático usando o MMQ.

Solução do Exemplo

Queremos encontrar $g(x) = c_0 + c_1x + c_2x^2$ onde temos que

$$\phi_0(x) = 1, \quad \phi_1(x) = x, \quad \phi_2(x) = x^2$$

Sendo assim, vamos primeiro montar os vetores que correspondem a avaliação de cada $\phi_j(x)$ nos pontos x_i dados na tabela.

Método dos mínimos quadrados

Solução do Exemplo

$$\phi_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad \phi_1 = \begin{bmatrix} -1 \\ 0 \\ 1 \\ 2 \end{bmatrix}, \quad \phi_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 4 \end{bmatrix}, \quad f = \begin{bmatrix} 0 \\ -1 \\ 0 \\ 7 \end{bmatrix}$$

Calculando os produtos escalares temos

$$\langle \phi_0, \phi_0 \rangle = 4$$

$$\langle \phi_0, \phi_1 \rangle = 2$$

$$\langle \phi_0, \phi_2 \rangle = 6$$

$$\langle \phi_1, \phi_1 \rangle = 6$$

$$\langle \phi_1, \phi_2 \rangle = 8$$

$$\langle \phi_2, \phi_2 \rangle = 18$$

$$\langle f, \phi_0 \rangle = 6$$

$$\langle f, \phi_1 \rangle = 14$$

$$\langle f, \phi_2 \rangle = 28$$

Método dos mínimos quadrados

Solução do Exemplo

Assim temos o seguinte sistema de equações lineares (equações normais)

$$\begin{bmatrix} 4 & 2 & 6 \\ 2 & 6 & 8 \\ 6 & 8 & 18 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 6 \\ 14 \\ 28 \end{bmatrix}$$

Resolvendo o sistema encontramos a seguinte solução


$$c_0 = -\frac{8}{5}, \quad c_1 = \frac{1}{5}, \quad c_2 = 2$$

logo a aproximação pelo MMQ é dada por

$$g(x) = -\frac{8}{5} + \frac{1}{5}x + 2x^2$$

Método dos mínimos quadrados

Solução do Exemplo



Método dos mínimos quadrados


Exemplo de ajuste polinomial pelo MMQ

Exemplo - Sala de Aula

x	0.0	1.0	2.0	2.5	3.0
y	2.9	3.7	4.1	4.4	5.0

Solução do Exemplo

$$g(x) = 2.92672414 + 0.64310345x$$



Conteúdo

- ▶ Aula passada
 - ▶ Caso discreto
 - ▶ Regressão linear
 - ▶ Caso geral
- ▶ Aula de hoje
 - ▶ Caso não-linear
 - ▶ Caso contínuo
 - ▶ Polinômio ortogonais

Mínimos Quadrados

Dados m pontos $(x_1, y_1), \dots, (x_m, y_m)$ deseja-se encontrar a função

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

que melhor se ajusta aos dados no sentido do método dos mínimos quadrados, considerando que as funções $\phi_j(x)$, $j = 0, 1, \dots, n$ são conhecidas.

Nesta situação estamos trabalhando com o MMQ no caso linear, pois a função $g(x)$ é uma função *linear* dos parâmetros c_0, c_1, \dots, c_n .

Veremos a seguir como lidar com o caso em que $g(x)$ é uma função não-linear dos parâmetros c_0, c_1, \dots, c_n .

Mínimos Quadrados

Caso Não-Linear

Vamos considerar agora que estamos interessados em ajustar uma curva $g(x)$ que é uma função não-linear dos parâmetros.

Alguns exemplos:

$$g(x) = c_0 e^{c_1 x}$$

$$g(x) = c_0 x^{c_1}$$

$$g(x) = \frac{1}{c_0 + c_1 x}$$

$$g(x) = c_0 c_1^x$$

Uma das formas de tratar essa situação é através da **transformação** ou **linearização** do modelo não-linear em um modelo linear.

Vamos ilustrar o procedimento através de um exemplo.

Mínimos Quadrados

Caso Não-Linear

Exemplo

Seja $f(x) = 20e^{-15x}$. Considere a seguinte tabela de dados

x_i	0.0	0.1	0.2	0.3	0.4
y_i	20.5	4.60	1.00	0.15	0.05

Solução do Exemplo

Queremos fazer um ajuste da seguinte forma

$$f(x) \approx g(x) = c_0 e^{c_1 x}$$

Temos que fazer uma transformação e linearizar o modelo

$$\begin{aligned}\ln f &\approx \ln (c_0 e^{c_1 x}) \\ &\approx \ln (c_0) + \ln (e^{c_1 x}) \\ &\approx \ln (c_0) + c_1 x\end{aligned}$$

Mínimos Quadrados

Caso Não-Linear

Exemplo

Assim temos

$$F(x) = a_0\phi_0(x) + a_1\phi_1(x)$$

onde

$$\phi_0(x) = 1$$

$$\phi_1(x) = x$$

com a seguinte mudança

$$a_0 = \ln(c_0)$$

$$a_1 = c_1$$

$$F = \ln f(x)$$

Mínimos Quadrados

Caso Não-Linear

Exemplo

Construimos os vetores

$$\phi_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \phi_1 = \begin{bmatrix} 0.0 \\ 0.1 \\ 0.2 \\ 0.3 \\ 0.4 \end{bmatrix}, F = \begin{bmatrix} \ln f(x_1) \\ \ln f(x_2) \\ \ln f(x_3) \\ \ln f(x_4) \\ \ln f(x_5) \end{bmatrix} = \begin{bmatrix} 3.02 \\ 1.52 \\ 0 \\ -1.89 \\ -2.99 \end{bmatrix}$$

para montar o sistema precisamos calcular

$$\begin{aligned} &< \phi_0, \phi_0 >, < \phi_0, \phi_1 >, < \phi_1, \phi_1 > \\ &< \phi_0, F >, < \phi_1, F > \end{aligned}$$

Mínimos Quadrados

Caso Não-Linear

Exemplo

assim podemos montar o sistema

$$\begin{bmatrix} 5 & 1.0 \\ 1.0 & 0.3 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} 0.35 \\ -1.335 \end{bmatrix}$$

cuja solução é dada por $a_0 = 2.88$ e $a_1 = -14.05$.

E assim, como

$$a_0 = \ln c_0 \Rightarrow e^{a_0} = c_0 \Rightarrow c_0 = e^{2.88} \Rightarrow \boxed{c_0 = 17.81}$$

$$a_1 = c_1 \Rightarrow \boxed{c_1 = -14.05}$$


logo a função que melhor aproxima os dados do exemplo é dada por

$$\boxed{g(x) = c_0 e^{c_1 x} = 17.81 e^{-14.05x}}$$

Mínimos Quadrados

Caso Não-Linear

Exemplo



Mínimos Quadrados

Caso Não-Linear

► Exemplo (1)

$$g(x) = \frac{1}{c_0 + c_1 x} \quad \Rightarrow \quad F(x) = \frac{1}{f(x)} \quad \text{e} \quad G(x) = c_0 + c_1 x$$

► Exemplo (2)

$$g(x) = c_0 x^{c_1} \quad \Rightarrow \quad F(x) = \ln f \quad \text{e} \quad G(x) = \ln c_0 + \ln x^{c_1}$$
$$G(x) = \ln c_0 + c_1 \ln x$$
$$G(x) = a_0 + a_1 \ln x$$

com $\phi_0 = 1$, $\phi_1 = \ln x$, $a_0 = \ln c_0$ e $a_1 = c_1$.

► Exemplo (3)

$$g(x) = c_0 c_1^x \quad \Rightarrow \quad F(x) = \ln f \quad \text{e} \quad G(x) = \ln c_0 + \ln c_1^x$$
$$G(x) = \ln c_0 + x \ln c_1$$
$$G(x) = a_0 + a_1 x$$

com $\phi_0 = 1$, $\phi_1 = x$, $a_0 = \ln c_0$ e $a_1 = \ln c_1$.

Mínimos Quadrados

Caso Não-Linear - Teste de Alinhamento

Em situações que só conhecemos a função através dos dados experimentais tabelados, surge a questão: *qual família de funções melhor aproxima os dados?*

Qual função $g(x)$ devemos usar: $g(x) = \frac{1}{c_0 + c_1 x}$ ou $g(x) = c_0 c_1^x$?

A idéia é aplicar o chamado teste de alinhamento:

1. Transformar $y = f(x)$ em

$$F_1(x) = a_0 \phi_0(x) + a_1 \phi_1(x)$$

$$F_2(x) = b_0 \bar{\phi}_0(x) + b_1 \bar{\phi}_1(x)$$

2. Plotar x vs $F_1(x)$ e x vs $F_2(x)$
3. Escolher aquela que o gráfico estiver "*mais linear*"

Mínimos Quadrados

Caso Não-Linear - Teste de Alinhamento

Exemplo

Considere a seguinte tabela

x_i	-8	-6	-4	-2	0	2	4
$f(x_i)$	30	10	9	6	5	4	4

Qual é a melhor opção ?

a) $g(x) = \frac{1}{c_0 + c_1 x}$

b) $g(x) = c_0 c_1^x$

Mínimos Quadrados

Caso Não-Linear - Teste de Alinhamento

Solução do Exemplo

Vamos linearizar as funções

a)

$$f(x) \approx g(x) = \frac{1}{c_0 + c_1 x}$$

obtemos

$$\begin{aligned}\frac{1}{f(x)} &\approx c_0 + c_1 x \\ F_1(x) = \frac{1}{f(x)} &= a_0 + a_1 x\end{aligned}$$

onde $a_0 = c_0$, $a_1 = c_1$, $\phi_0 = 1$ e $\phi_1 = x$.

Mínimos Quadrados

Caso Não-Linear - Teste de Alinhamento

Solução do Exemplo

b)

$$f(x) \approx g(x) = c_0 c_1^x$$

obtemos

$$\ln f \approx \ln c_0 + x \ln c_1$$

$$F_2(x) = a_0 + a_1 x$$

onde $a_0 = \ln c_0$, $a_1 = \ln c_1$, $\phi_0 = 1$ e $\phi_1 = x$.

Temos que

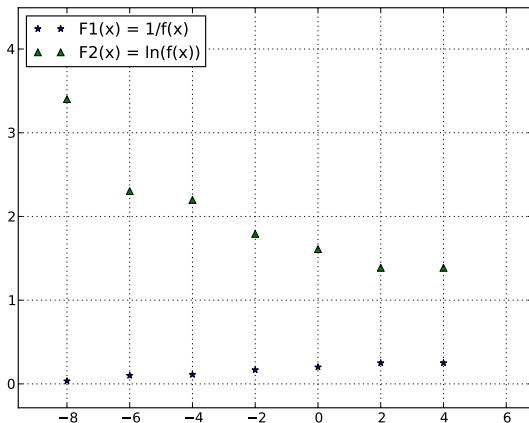
$$F_1(x) = \frac{1}{f(x)}, \quad F_2(x) = \ln f(x)$$

Vamos fazer os gráficos de x contra $F_1(x)$ e x contra $F_2(x)$ para o teste de alinhamento.

Mínimos Quadrados

Caso Não-Linear - Teste de Alinhamento

Solução do Exemplo



Logo vemos que $F_1(x)$ é mais adequada para o ajuste de curva.



Mínimos Quadrados

Caso Contínuo

Até então trabalhamos em como *aproximar* uma função $f(x)$ por uma função $g(x)$ em um conjunto de pontos x_i onde conhecemos o valor de $f(x_i)$. (**caso discreto**)

Vamos considerar agora o **caso contínuo**, onde queremos aproximar $f(x)$ que é uma função conhecida para todo x em um intervalo $[a, b]$, por uma função $g(x)$ na forma

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

onde $\phi_0(x), \dots, \phi_n(x)$ são funções contínuas e conhecidas.

Para apresentar o método vamos considerar o seguinte caso

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x)$$

Mínimos Quadrados

Caso Contínuo

Lembrando que o produto escalar entre duas funções contínuas no intervalo $[a, b]$ é definido por

$$\langle f, g \rangle = \int_a^b f(x)g(x) \, dx$$

podemos então medir a distância de $f(x)$ a $g(x)$ fazendo

$$\langle f - g, f - g \rangle = \int_a^b [f(x) - g(x)]^2 \, dx$$

no caso discreto tínhamos

$$\langle f - g, f - g \rangle = \sum_{i=1}^m [f(x_i) - g(x_i)]^2$$

Mínimos Quadrados

Caso Contínuo

Considerando que $r = f - g$, temos

$$\begin{aligned}\langle r, r \rangle &= \int_a^b [f(x) - g(x)]^2 dx = \int_a^b [f - c_0\phi_0 - c_1\phi_1]^2 dx \\&= \int_a^b [f^2 - 2c_0f\phi_0 - 2c_1f\phi_1 + c_0^2\phi_0^2 + 2c_0c_1\phi_0\phi_1 + c_1^2\phi_1^2] dx \\&= \int_a^b f^2 dx - 2c_0 \int_a^b f\phi_0 dx - 2c_1 \int_a^b f\phi_1 dx \\&\quad + c_0^2 \int_a^b \phi_0^2 dx + 2c_0c_1 \int_a^b \phi_0\phi_1 dx + c_1^2 \int_a^b \phi_1^2 dx\end{aligned}$$

No método dos mínimos quadrados procuramos o ponto de mínimo da função $\langle r, r \rangle = \langle r, r \rangle (c_0, c_1)$. Precisamos calcular as derivadas parciais de $\langle r, r \rangle$ com relação a c_0 e c_1 .

Mínimos Quadrados

Caso Contínuo

Calculando as derivadas parciais e igualando a zero temos

$$\frac{\partial \langle r, r \rangle}{\partial c_0} = -2 \int_a^b f \phi_0 \, dx + 2c_0 \int_a^b \phi_0 \phi_0 \, dx + 2c_1 \int_a^b \phi_0 \phi_1 \, dx = 0$$

$$\frac{\partial \langle r, r \rangle}{\partial c_1} = -2 \int_a^b f \phi_1 \, dx + 2c_1 \int_a^b \phi_1 \phi_1 \, dx + 2c_0 \int_a^b \phi_0 \phi_1 \, dx = 0$$

organizando os termos, temos

$$c_0 \int_a^b \phi_0 \phi_0 \, dx + c_1 \int_a^b \phi_0 \phi_1 \, dx = \int_a^b f \phi_0 \, dx$$

$$c_1 \int_a^b \phi_1 \phi_1 \, dx + c_0 \int_a^b \phi_0 \phi_1 \, dx = \int_a^b f \phi_1 \, dx$$

usando a notação $\langle \phi_i, \phi_j \rangle = \int_a^b \phi_i(x) \phi_j(x) \, dx$, podemos escrever

Mínimos Quadrados

Caso Contínuo

$$c_0 \langle \phi_0, \phi_0 \rangle + c_1 \langle \phi_0, \phi_1 \rangle = \langle f, \phi_0 \rangle$$

$$c_1 \langle \phi_1, \phi_0 \rangle + c_0 \langle \phi_1, \phi_1 \rangle = \langle f, \phi_1 \rangle$$

que é um sistema de equações lineares (*equações normais*), o qual pode ser escrito de forma matricial como

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \end{bmatrix}$$

Obs: o procedimento é similar ao caso discreto, a diferença é na forma de se calcular os produtos escalares, pois no caso contínuo temos que calcular as integrais

$$\langle \phi_0(x), \phi_1(x) \rangle = \int_a^b \phi_0(x) \phi_1(x) dx$$

$$\langle f(x), \phi_0(x) \rangle = \int_a^b f(x) \phi_0(x) dx, \dots$$

Mínimos Quadrados

Caso Contínuo

Exemplo

Seja $f(x) = x^4 - 5x$, $x \in [-1, 1]$. Vamos aproximar $f(x)$ por um polinômio de segundo grau usando o MMQ.

Solução do Exemplo

$f(x)$ é contínua no intervalo $[-1, 1]$.

Queremos

$$f(x) \approx g(x) = c_0 + c_1x + c_2x^2$$

onde usamos as funções $\phi_0(x) = 1$, $\phi_1(x) = x$, $\phi_2(x) = x^2$.

Precisamos resolver o sistema de equações normais

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle & \langle \phi_0, \phi_2 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle & \langle \phi_1, \phi_2 \rangle \\ \langle \phi_2, \phi_0 \rangle & \langle \phi_2, \phi_1 \rangle & \langle \phi_2, \phi_2 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \\ \langle f, \phi_2 \rangle \end{bmatrix}$$

Mínimos Quadrados

Caso Contínuo

Exemplo

Substituindo $\phi_0(x) = 1, \phi_1(x) = x, \phi_2(x) = x^2$, temos

$$\begin{bmatrix} \langle 1, 1 \rangle & \langle 1, x \rangle & \langle 1, x^2 \rangle \\ \langle x, 1 \rangle & \langle x, x \rangle & \langle x, x^2 \rangle \\ \langle x^2, 1 \rangle & \langle x^2, x \rangle & \langle x^2, x^2 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \\ \langle f, \phi_2 \rangle \end{bmatrix}$$

usando o produto escalar usual em $[-1, 1]$ definido por

$$\langle f, g \rangle = \int_a^b f(x)g(x) \, dx \quad \Rightarrow \quad \int_{-1}^1 f(x)g(x) \, dx$$

temos

$$\langle 1, 1 \rangle = \int_{-1}^1 dx = x \Big|_{-1}^1 = 2$$

$$\langle 1, x \rangle = \int_{-1}^1 x \, dx = \frac{x^2}{2} \Big|_{-1}^1 = 0 = \langle x, 1 \rangle$$

$$\langle 1, x^2 \rangle = \int_{-1}^1 x^2 \, dx = \frac{x^3}{3} \Big|_{-1}^1 = \frac{2}{3} = \langle x^2, 1 \rangle$$

Mínimos Quadrados

Caso Contínuo

Exemplo

$$\langle x, x \rangle = \int_{-1}^1 x^2 dx = \left. \frac{x^3}{3} \right]_{-1}^1 = \frac{2}{3}$$

$$\langle x, x^2 \rangle = \int_{-1}^1 x^3 dx = \left. \frac{x^4}{4} \right]_{-1}^1 = 0 = \langle x^2, x \rangle$$

$$\langle x^2, x^2 \rangle = \int_{-1}^1 x^4 dx = \left. \frac{x^5}{5} \right]_{-1}^1 = \frac{2}{5}$$

e ainda

$$\langle f, 1 \rangle = \int_{-1}^1 x^4 - 5x dx = \left. \frac{x^5}{5} - \frac{5x^2}{2} \right]_{-1}^1 = \left(\frac{1}{5} - \frac{5}{2} \right) - \left(-\frac{1}{5} - \frac{5}{2} \right) = \frac{2}{5}$$

$$\langle f, x \rangle = \int_{-1}^1 x^5 - 5x^2 dx = \left. \frac{x^6}{6} - \frac{5x^3}{3} \right]_{-1}^1 = -\frac{10}{3}$$

$$\langle f, x^2 \rangle = \int_{-1}^1 x^6 - 5x^3 dx = \left. \frac{x^7}{7} - \frac{5x^4}{4} \right]_{-1}^1 = \frac{2}{7}$$

Mínimos Quadrados

Caso Contínuo

Exemplo

Assim o sistema de equações normais é dado por

$$\begin{bmatrix} 2 & 0 & \frac{2}{3} \\ 0 & \frac{2}{3} & 0 \\ \frac{2}{3} & 0 & \frac{2}{5} \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \frac{2}{5} \\ -\frac{10}{3} \\ \frac{2}{7} \end{bmatrix}$$

resolvendo com o método de Cholesky, por exemplo, obtemos a seguinte solução

$$c_0 = -\frac{3}{35}, \quad c_1 = -5, \quad c_2 = \frac{6}{7}$$


e assim

$$g(x) = -\frac{3}{35} - 5x + \frac{6}{7}x^2$$

Mínimos Quadrados

Caso Contínuo

Exemplo



Mínimos Quadrados

Ortogonalidade

Quando o produto escalar, no caso discreto ou no contínuo, é igual a zero, dizemos que os vetores (caso discreto) ou funções (caso contínuo) são ortogonais.

Exemplos

Discreto

$$\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^2 x_i y_i = x_1 y_1 + x_2 y_2 = 1(0) + 0(1) = 0$$

Contínuo

$$f(x) = \sin(x), \quad g(x) = \cos(x)$$

$$\langle f, g \rangle = \int_{-\pi}^{\pi} \sin(x) \cos(x) \, dx = 0$$

Mínimos Quadrados

Ortogonalidade

Podemos também usar o produto escalar com peso, dado por uma função $w(x)$. Nesse caso o produto escalar é dado por:

- ▶ caso contínuo

$$\langle f, g \rangle = \int_a^b w(x) f(x) g(x) dx$$

- ▶ caso discreto

$$\langle f, g \rangle = \sum_{i=1}^m w(x_i) f(x_i) g(x_i)$$

e temos também a mesma noção de vetores ou funções ortogonais.

Mínimos Quadrados

Ortogonalidade

Note que até agora trabalhamos com o seguinte conjunto de funções

$$\phi_0(x) = 1, \quad \phi_1(x) = x, \quad \dots, \quad \phi_n(x) = x^n$$

o qual constitui uma base para o espaço vetorial dos polinômios de grau menor ou igual a n . Observe que se trabalharmos com um conjunto de funções ϕ_j que são ortogonais entre si, isto é, que satisfazem

$$\langle \phi_i, \phi_j \rangle = 0, \quad \forall i \neq j \quad (5)$$

então o sistema normal tem a seguinte forma (diagonal)

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & 0 & \dots & 0 \\ 0 & \langle \phi_1, \phi_1 \rangle & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \langle \phi_n, \phi_n \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \\ \vdots \\ \langle f, \phi_n \rangle \end{bmatrix}$$

Mínimos Quadrados

Ortogonalidade

Neste caso a solução é facilmente calculada tomando

$$\begin{aligned} \langle \phi_0, \phi_0 \rangle c_0 &= \langle f, \phi_0 \rangle & \Rightarrow & c_0 = \frac{\langle f, \phi_0 \rangle}{\langle \phi_0, \phi_0 \rangle} \\ \langle \phi_1, \phi_1 \rangle c_1 &= \langle f, \phi_1 \rangle & \Rightarrow & c_1 = \frac{\langle f, \phi_1 \rangle}{\langle \phi_1, \phi_1 \rangle} \\ & \vdots & & \\ \langle \phi_n, \phi_n \rangle c_n &= \langle f, \phi_n \rangle & \Rightarrow & c_n = \frac{\langle f, \phi_n \rangle}{\langle \phi_n, \phi_n \rangle} \end{aligned}$$

isto é, para $i = 0, 1, \dots, n$

$$c_i = \frac{\langle f, \phi_i \rangle}{\langle \phi_i, \phi_i \rangle}$$

(6)

Mínimos Quadrados

Ortogonalidade

Existem várias *famílias* de polinômios ortogonais, e estes podem ser construídos com *diferentes produtos escalares*, dependendo do intervalo, da função peso, ou de ser contínua ou discreta a aplicação.

A seguir veremos 2 exemplos de famílias de polinômios ortogonais:

- ▶ Polinômios de Legendre
- ▶ Polinômios de Chebyshev

Mínimos Quadrados

Polinômios de Legendre

Os polinômios de Legendre são ortogonais no intervalo $[-1, 1]$ com a função peso $w(x) = 1$.

Os primeiros polinômios são dados por

$$P_0(x) = 1$$

$$P_1(x) = x$$

$$P_2(x) = \frac{1}{2}(3x^2 - 1)$$

$$P_3(x) = \frac{1}{2}(5x^3 - 3x)$$

$$P_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3)$$

...

De forma geral eles podem ser escritos como

$$P_k(x) = \frac{1}{(2^k)k!} \frac{d^k}{dx^k} [(x^2 - 1)]^k, \quad k = 1, \dots$$

Mínimos Quadrados

Polinômios de Legendre

Vamos verificar para alguns casos, que de fato os polinômios de Legendre são ortogonais.

$$\langle P_1, P_0 \rangle = \int_{-1}^1 x \, dx = \left[\frac{x^2}{2} \right]_{-1}^1 = 0$$


$$\langle P_1, P_1 \rangle = \int_{-1}^1 x^2 \, dx = \left[\frac{x^3}{3} \right]_{-1}^1 = \frac{2}{3}$$

$$\begin{aligned} \langle P_1, P_2 \rangle &= \int_{-1}^1 x \frac{1}{2} (3x^2 - 1) \, dx = \frac{1}{2} \int_{-1}^1 3x^3 - x \, dx \\ &= \frac{1}{2} \left[\frac{3}{4} x^4 - \frac{x^2}{2} \right]_{-1}^1 = \frac{1}{2} \left[\left(\frac{3}{4} - \frac{1}{2} \right) - \left(\frac{3}{4} - \frac{1}{2} \right) \right] = 0 \end{aligned}$$

$$\langle P_1, P_3 \rangle = \int_{-1}^1 x \frac{1}{2} (5x^3 - 3x) \, dx = \dots = 0$$

Mínimos Quadrados

Polinômios de Legendre



Mínimos Quadrados

Polinômios de Chebyshev

Os polinômios de Chebyshev são ortogonais no intervalo $[-1, 1]$ com a seguinte função peso: $w(x) = \frac{1}{\sqrt{1-x^2}}$.

Os primeiros polinômios são dados por

$$P_0(x) = 1$$

$$P_1(x) = x$$

$$P_2(x) = 2x^2 - 1$$


$$P_3(x) = 4x^3 - 3x$$

$$P_4(x) = 8x^4 - 8x^2 + 1$$

...


Mínimos Quadrados

Polinômios de Chebyshev



Mínimos Quadrados

Polinômios de Chebyshev



Mínimos Quadrados

Exemplo com polinômios de Legendre

Exemplo

Use o MMQ com os polinômios de Legendre para encontrar a função $g(x) = c_0\phi_0(x) + c_1\phi_1(x) + c_2\phi_2(x)$ considerando que $\phi_0(x) = 1$, $\phi_1(x) = x$ e $\phi_2(x) = \frac{1}{2}(3x^2 - 1)$, que melhor se ajusta à $f(x) = e^x$ no intervalo $[-1, 1]$.

Solução do Exemplo

Como estamos trabalhando com polinômios ortogonais, podemos encontrar os parâmetros c_0 , c_1 e c_2 usando

$$c_i = \frac{\langle f, \phi_i \rangle}{\langle \phi_i, \phi_i \rangle}$$

Para isso temos que calcular

- ▶ $\langle f, \phi_0 \rangle$, $\langle f, \phi_1 \rangle$, $\langle f, \phi_2 \rangle$
- ▶ $\langle \phi_0, \phi_0 \rangle$, $\langle \phi_1, \phi_1 \rangle$, $\langle \phi_2, \phi_2 \rangle$

Mínimos Quadrados

Exemplo com polinômios de Legendre

Solução do Exemplo

Calculando

$$\langle \phi_0, \phi_0 \rangle = \int_{-1}^1 dx = x \Big|_{-1}^1 = 1 - (-1) = 2$$

$$\langle \phi_1, \phi_1 \rangle = \int_{-1}^1 x^2 dx = \frac{x^3}{3} \Big|_{-1}^1 = \frac{1}{3} - \left(-\frac{1}{3}\right) = \frac{2}{3}$$

$$\begin{aligned} \langle \phi_2, \phi_2 \rangle &= \int_{-1}^1 \frac{1}{2}(3x^2 - 1) \frac{1}{2}(3x^2 - 1) dx \\ &= \frac{1}{4} \int_{-1}^1 (9x^4 - 6x^2 + 1) dx = \frac{1}{4} \left[\frac{9x^5}{5} - \frac{6x^3}{3} + x \right]_{-1}^1 \\ &= \frac{1}{4} \left[\left(\frac{9}{5} - 2 + 1 \right) - \left(-\frac{9}{5} + 2 - 1 \right) \right] \\ &= \dots = \frac{2}{5} \end{aligned}$$

Mínimos Quadrados

Exemplo com polinômios de Legendre

Solução do Exemplo

Calculando

$$\langle f, \phi_0 \rangle = \int_{-1}^1 e^x dx = e^x \Big|_{-1}^1 = e^1 - e^{-1} = 2.35$$

$$\begin{aligned}\langle f, \phi_1 \rangle &= \int_{-1}^1 x e^x dx \quad \Rightarrow \quad \text{IPP : } \boxed{\int u dv = uv - \int v du} \\ &= x e^x \Big|_{-1}^1 - \int_{-1}^1 e^x dx = x e^x \Big|_{-1}^1 - e^x \Big|_{-1}^1 \\ &= e^x (x - 1) \Big|_{-1}^1 = [e^1(1 - 1) - e^{-1}(-2)] \\ &= 2e^{-1} = 0.736\end{aligned}$$

Mínimos Quadrados

Exemplo com polinômios de Legendre

Solução do Exemplo

Calculando

$$\begin{aligned}\langle f, \phi_2 \rangle &= \int_{-1}^1 e^x \frac{1}{2}(3x^2 - 1) dx \quad \text{IPP} \quad \Rightarrow \quad u = (3x^2 - 1), \quad dv = e^x \\&= \frac{1}{2} \left[(3x^2 - 1)e^x \Big|_{-1}^1 - 6 \int_{-1}^1 e^x x dx \right] \\&= \frac{1}{2} [(2e^1 - 2e^{-1}) - 6 (0.736)] = \frac{1}{2} [2 (2.35) - 4.414] \\&= 0.143\end{aligned}$$

Mínimos Quadrados

Exemplo com polinômios de Legendre

Solução do Exemplo

Assim temos que os coeficientes são

$$c_0 = \frac{\langle f, \phi_0 \rangle}{\langle \phi_0, \phi_0 \rangle} = \frac{2.35}{2} = 1.175$$

$$c_1 = \frac{\langle f, \phi_1 \rangle}{\langle \phi_1, \phi_1 \rangle} = \frac{0.736}{2/3} = 1.104$$

$$c_2 = \frac{\langle f, \phi_2 \rangle}{\langle \phi_2, \phi_2 \rangle} = \frac{0.143}{2/5} = 0.358$$

e portanto

$$\begin{aligned} g(x) &= c_0 \phi_0 + c_1 \phi_1 + c_2 \phi_2 \\ &= c_0 + c_1 x + c_2 [0.5 (3x^2 - 1)] \\ &= 1.175 + 1.104 x + 0.358 [0.5(3x^2 - 1)] \end{aligned}$$

é a função que melhor aproxima $f(x) = e^x$ em $[-1, 1]$ segundo o critério dos mínimos quadrados.

Mínimos Quadrados

Exemplo com polinômios de Legendre

Solução do Exemplo

